

변동성 예측을 결합한 블랙-리터만 저변동성 포트폴리오 전략

Black-Litterman Low-Volatility Portfolio Strategy with Volatility Forecasting

서윤범 (Yunbeom Seo)

소속(국문): 팀 스파르타

소속(영문): Team Sparta

E-mail : sybeom528@gmail.com

김하연 (Hayeon Kim)

소속(국문): 팀 스파르타

소속(영문): Team Sparta

E-mail : hy2000627@gmail.com

김재천 (Jaecheon Kim)

소속(국문): 팀 스파르타

소속(영문): Team Sparta

E-mail : gorhkdwj@gmail.com

김윤서 (Yoonseo Kim)

소속(국문): 팀 스파르타

소속(영문): Team Sparta

E-mail : rladbstj56@gmail.com

변동성 예측을 결합한 블랙-리터만 저변동성 포트폴리오 전략

국문초록

블랙-리터만(Black-Litterman, BL) 모형은 시장 균형에 투자자 뷰를 결합하여 평균-분산 최적화의 추정 오차 민감성을 완화하지만, 뷰가 전문가의 주관에 의존한다는 한계를 갖는다. 이를 보완하기 위한 머신러닝 기반 BL 응용 연구가 활발하나 대부분 수익률 예측에 집중되어 있고, 변동성 예측을 직접 뷰로 활용하는 연구는 제한적이다. 본 연구는 인공신경망(ANN) 기반 변동성 예측을 BL 뷰로 결합한 Pyo and Lee (2018)의 프레임워크를 출발점으로, 두 축으로 확장한다: (1) 단순 ANN을 LSTM과 HAR의 앙상블로 대체하여 시계열 의존 구조를 반영하고, (2) BL의 네 입력 슬롯 ($\mathbf{p}, q, \omega, \mathbf{w}_{mkt}$)을 각각 복수의 후보로 정의해 곱집합으로 결합한 90개 슬롯 조합을 체계적으로 탐색한다. 2010–2025년 S&P 500 617 종목, 192개월 실증 분석에서 LSTM-HAR 앙상블은 ANN 대비 변동성 예측 정확도에서 일관된 우위를 보였으며 특히 COVID-19가 포함된 위기 국면(R3)에서 격차가 가장 크게 확대되었다. 이 예측 우위가 포트폴리오 성과로 전이되기 위해서는 뷰 포트폴리오의 대형주 비중 집중 완화($\mathbf{p}^{eq}, \mathbf{p}^{rp}$)가 동반되어야 한다. 본 연구가 제안하는 두 슬롯 옵션 — 모든 시장 국면에서 저변동 뷰를 일관되게 유지하는 Ensemble-defensive(샤프 비율 1.04–1.07) 와 강세장 적응을 허용하는 Ensemble-adaptive(샤프 비율 1.05–1.10) —는 편측 20bp 거래비용 차감 후에도 SPY(0.93), 1/N(0.86), Risk Parity(0.89), ANN-anchor(0.95) 대비 일관된 성과 우위를 보였다. 다만 이러한 우위의 통계적 유의성은 표본 기간 제약 등으로 제한적이며, 통계적 확립은 위기 국면(R3)에서 저변동 뷰의 안정성($q \geq 0$)과 대형주 편중 완화가 결합된 슬롯 조합에 국한된다. 본 연구는 90개 슬롯의 차원별 주변 분포와 국면별 결과 분석을 통해 변동성 기반 BL 저변동 전략의 운용 목표별 슬롯 선택 근거를 제시한다.

주제어: 블랙-리터만, 변동성 예측, LSTM, HAR, 저변동 포트폴리오

Black-Litterman Low-Volatility Portfolio Strategy with Volatility Forecasting

Abstract

The Black-Litterman (BL) model mitigates the estimation-error sensitivity of mean-variance optimization by combining market equilibrium with investor views, yet its reliance on subjectively formed views remains a limitation. While machine learning has been applied to BL, most work focuses on return forecasting, leaving volatility-based views underexplored. Building on Pyo and Lee's (2018) ANN-based volatility BL framework, we extend it in two ways: (i) replacing the ANN with a performance-weighted LSTM-HAR ensemble for multi-scale forecasting, and (ii) systematically exploring 90 combinations of the four BL input slots ($\mathbf{p}, q, \omega, \mathbf{w}_{mkt}$). Using 617 S&P 500 constituents

over 2010-2025 (192 months), the LSTM-HAR ensemble consistently outperforms the ANN in forecasting accuracy, with the largest gap during the crisis regime (R3, including COVID-19). Translating this advantage into portfolio performance also requires mitigating the view portfolio's large-cap concentration through equal ($\mathbf{p}^{eq}$) or risk-parity ($\mathbf{p}^{rp}$) weighting. Our two proposed configurations—Ensemble-defensive (Sharpe ratio 1.04–1.07), maintaining low-volatility views across regimes, and Ensemble-adaptive (Sharpe ratio 1.05–1.10), allowing bull-market adaptation—achieve higher observed Sharpe ratios than SPY (0.93), 1/N portfolio (0.86), Risk Parity (0.89), and ANN-anchor (0.95) after 20 basis points of one-sided transaction costs. However, statistical significance of these advantages is limited by sample-period constraints, with confirmation largely confined to R3 slot combinations satisfying view sign stability ($q \geq 0$) and concentration mitigation. By combining dimension-wise marginal and regime-conditional analyses, this study provides objective-specific guidance for slot selection in volatility-driven BL low-volatility strategies.

Key Words: Black-Litterman model, volatility forecasting, LSTM, HAR, low-volatility portfolio

1. 서론

마코위츠의 평균-분산 최적화(Mean-Variance Optimization, MVO, Markowitz, 1952) 이래로 포트폴리오 구성 이론은 기대수익률과 위험의 절충을 다루는 방법론을 다수 발전시켜왔다. 그러나 MVO는 입력값의 추정 오차에 극도로 민감하여, 최적해가 표본 외에서 불안정하고 입력값의 작은 변화에도 극단적인 가중치를 산출한다는 한계가 지적되어 왔다. 이러한 한계에 대응하기 위해 수축(shrinkage) 추정(Ledoit & Wolf, 2004), 베이저안 접근 등 다양한 후속 연구가 제안되어 왔다. 그 중 Black and Litterman (1992)이 제안한 블랙-리터만 모형(Black-Litterman, BL)은 시장 균형 수익률을 사전 분포로 두고 투자자의 견해(뷰, view)를 결합해 사후 기대수익률을 도출하는 베이저안 방법론으로, 추정 오차를 완화하면서도 투자 전문가의 견해를 반영하여 포트폴리오 가중치를 설정할 수 있어 폭넓게 연구되어왔다. 그러나 이 견해가 전문가의 주관적 판단에 의존한다는 한계가 존재한다.

앞선 한계를 해결하기 위해, 투자자의 뷰를 머신러닝 기반으로 예측하는 다수의 연구가 진행되어 왔다. BL 프레임워크의 핵심은 포트폴리오 뷰 $\mathbf{p}$ 와 기대수익률 뷰 $\mathbf{q}$ 의 설정에 있으며, 머신러닝 기반 BL 응용 연구는 주로 $\mathbf{q}$ 를 트리 기반, 신경망, LLM 등의 모형으로 예측하여 뷰로 주입하는 방식을 취해왔다(Barua & Sharma, 2023; Lee et al., 2025; Su et al., 2026). 이들은 머신러닝 기반 수익률 예측이 BL 프레임워크의 뷰 정량화에 효과적으로 활용될 수 있음을 보였다.

한편 BL의 뷰는 반드시 기대수익률에 국한될 필요는 없다. 자산의 변동성 또한 포트폴리오 구성에서 중요한 요소이며, 저위험 이상현상(저베타, 저변동 종목이 위험 대비 우수한 수익을 보이는

현상)은 변동성을 직접 뷰로 활용할 수 있는 근거를 제공한다(Baker et al., 2011; Frazzini and Pedersen, 2014; Blitz and van Vliet, 2007). 다만, 본 연구는 이상현상 자체의 검증이 아닌, 현상의 존재를 출발점으로 BL 프레임워크 내에서 변동성을 신호로서 효과적으로 활용하는 방법에 초점을 둔다.

변동성 기반의 머신러닝 접근은 수익률 기반 응용 연구 대비 비교적 부족한 영역으로 남아있으며, 이 관점에서 Pyo and Lee (2018)는 인공신경망(Artificial Neural Network, ANN) 기반 변동성 예측을 활용해 종목을 저위험·고위험으로 분류하고, BL 뷰로 결합하는 방법을 KOSPI 200에 적용하여 BL 기반 포트폴리오가 샤프 비율(Sharpe ratio) 0.70을 달성하여 시가총액 비중(0.36) 및 시장 지수(0.59) 대비 우위를 보였다.

그러나 이 방식에는 두 가지 측면에서 추가 검토의 여지를 남긴다. 첫째, ANN 기반의 단순한 변동성 예측은 시계열 구조에 특화된 모형 구조가 아니며, 변동성의 다중 시간 척도와 순차적 의존성을 모형 차원에서 직접 반영하지 못해 예측 정확도에 한계가 있다(Corsi, 2009). 둘째, BL 프레임워크의 운영 핵심인 포트폴리오 뷰 $\mathbf{p}$ 와 기대수익률 뷰 q 의 구성이 저변동성(Low-Volatility) 포트폴리오 성과에 미치는 영향이 체계적으로 검토되지 않았다. 일반적 포트폴리오 구성 연구에서 DeMiguel et al. (2009)와 Maillard et al. (2010) 등은 시가총액 대비 동일 가중(equal-weighted, eq)·리스크 패리티(risk parity, rp)가 포트폴리오 효율성 측면에서 우위를 보일 수 있음을 보고하였다. 또한, 기대수익률 뷰 q 를 Fama-French 회귀 기반 예측값으로 산출하였으나, 해당 예측값의 부호와 크기가 저변동 포트폴리오의 성과에 미치는 영향에 대해서는 체계적인 비교·분석이 미비한 실정이다.

본 연구는 위 두 영역에 대해 다음과 같이 기여한다. 먼저, LSTM(Long Short-Term Memory)과 HAR(Heterogeneous Autoregressive) 앙상블 모형을 적용하여 변동성의 다중 시간 척도와 순차적 의존성을 동시에 반영하는 예측 구조를 제안한다. 다음으로, BL 프레임워크의 네 가지 핵심 슬롯($\mathbf{p}, q, \omega, \mathbf{w}_{mkt}$)에 걸쳐 90개 조합을 체계적으로 탐색함으로써, 저변동 전략의 효과를 극대화할 수 있는 최적의 포트폴리오 슬롯 설정을 제시한다. 이는 비시계열 모형과 고정된 슬롯 구성에 의존했던 선행 연구(Pyo & Lee, 2018)를 예측 모형과 포트폴리오 구조 설계라는 두 가지 축 모두에서 유의미하게 확장하였다는 점에서 차별성을 갖는다.

본 연구는 다음과 같은 순서로 구성된다. 2절에서는 변동성 예측 및 BL 응용에 관한 선행 연구를 검토하고, 3절에서는 본 연구의 변동성 예측 모형과 BL 프레임워크의 구조 및 슬롯 구성을 기술한다. 4절에서는 실증 분석 결과를 제시하고, 마지막 5절에서는 연구 결론과 한계점을 논의한다.

2. 선행 연구

2.1. 블랙-리터만

블랙-리터만 모형(Black-Litterman, BL, Black & Litterman, 1992)은 시장 균형 수익률과 투자자의 뷰를 베이지안 방식으로 결합하는 포트폴리오 최적화 프레임워크로, MVO가 갖는 추정 오차 민감성을 완화하는 데 효과적이다. 모형은 이차 효용 최대화 문제의 역산으로 도출되는 시장 균형 초과수익률 벡터 $\boldsymbol{\pi}$ 에서 출발한다.

$$\boldsymbol{\pi} = \lambda \boldsymbol{\Sigma} \mathbf{w}_{mkt} \quad (1)$$

여기서 $\boldsymbol{\pi} \in \mathbb{R}^{n \times 1}$ 은 균형 초과수익률 벡터, $\boldsymbol{\Sigma} \in \mathbb{R}^{n \times n}$ 은 초과수익률 공분산 행렬, $\mathbf{w}_{mkt} \in \mathbb{R}^{n \times 1}$ 은 시장 비중 벡터, λ 는 시장 위험회피계수이다. λ 는 모형 외부에서 주어지는 하이퍼파라미터로, He and Litterman (1999)은 미국 주식시장의 역사적 위험-수익 관계로부터 $\lambda \approx 2.5$ 를 제안하였으며, 이후 BL 응용 문헌의 표준값으로 널리 채택되었다. 공분산 행렬 $\boldsymbol{\Sigma}$ 의 추정은 자산 수 n 이 표본 길이 T 에 비해 클 때 표본 공분산이 큰 추정 오차를 갖는다는 문제가 알려져 있다. Ledoit and Wolf (2004)는 표본 공분산을 구조화된 타깃과 선형 결합하는 수축(shrinkage) 추정량을 제안하여 이 문제를 완화하였으며, 이후 고차원 포트폴리오 추정에서 폭넓게 활용되어 왔다.

사전 분포(prior)는 다음과 같이 설정된다.

$$\boldsymbol{\mu} \sim N(\boldsymbol{\pi}, \tau \boldsymbol{\Sigma}) \quad (2)$$

τ 는 사전 분포의 불확실성을 조절하며, He and Litterman (1999)은 사전 분포에 약한 신뢰도를 부여할 때 τ 를 작은 값(0.025)으로 두는 관행을 확립하였다.

투자자의 뷰는 다음과 같이 표현된다.

$$q | \boldsymbol{\mu} \sim N(\mathbf{p} \boldsymbol{\mu}, \omega) \quad (3)$$

여기서 $\mathbf{p} \in \mathbb{R}^{1 \times n}$ 은 뷰 포트폴리오 가중치 벡터, $q \in \mathbb{R}$ 은 단일 상대 뷰의 기대수익률 스칼라, $\omega \in \mathbb{R}$ 는 뷰의 불확실성을 나타내는 스칼라다. ω 의 구체적 형태는 BL 응용 문헌에서 다양하게 논의되었으며, He and Litterman (1999)은 $\omega = \tau \mathbf{p} \boldsymbol{\Sigma} \mathbf{p}^T$ 와 같이 사전 분포의 공분산에 비례하는 형태를 표준으로 제시하였다.

사전 분포와 뷰 우도를 결합하면 사후 기대수익률과 공분산은 다음과 같이 도출된다.

$$\boldsymbol{\Sigma}_{BL} = [(\tau \boldsymbol{\Sigma})^{-1} + \mathbf{p}^T \omega^{-1} \mathbf{p}]^{-1} \quad (4)$$

$$\boldsymbol{\mu}_{BL} = [(\tau \boldsymbol{\Sigma})^{-1} + \mathbf{p}^T \omega^{-1} \mathbf{p}]^{-1} [(\tau \boldsymbol{\Sigma})^{-1} \boldsymbol{\pi} + \mathbf{p}^T \omega^{-1} q] \quad (5)$$

최적 포트폴리오 비중은 다음을 풀어 산출한다.

$$\min_{\mathbf{w}} \frac{1}{2} \lambda \mathbf{w}^T \Sigma_{BL} \mathbf{w} - \mathbf{w}^T \boldsymbol{\mu}_{BL} \quad (6)$$

$$\text{s.t.} \quad \sum_{i=1}^n w_i = 1$$

2.2. 변동성 예측 모형

금융 자산의 변동성은 시계열적으로 특정 구조가 지속되는 '변동성 군집성(volatility clustering)'과 시차가 길어져도 자기상관이 천천히 감소하는 '장기 의존성(long-memory)'을 보인다(Cont, 2001). 본 절에서는 이러한 변동성 시계열 구조에 널리 활용되어 온 선형 모형인 HAR(Müller et al., 1997)과 비선형 시퀀스 학습에 특화된 딥러닝 모형인 LSTM(Hochreiter & Schmidhuber, 1997)의 구조를 기술한다. 아울러 서로 다른 가정에 기반한 두 모형의 예측값을 결합함으로써 동적 적응성(dynamic adaptability)을 확보하는 앙상블 접근법의 이론적 배경을 정리한다.

2.2.1. HAR

Müller et al. (1997)은 시장 참여자의 의사결정 시간 지평(time horizon)이 단기·중기·장기로 이질적이라는 '이질적 시장 가정(Heterogeneous Market Hypothesis)'을 제안하였다. 이 가정에 따르면, 변동성의 장기 의존 구조는 서로 다른 시간 척도를 가진 거래 행동이 중첩된 결과로 해석된다. Corsi (2009)는 이를 단순 선형 회귀 형태로 구현한 HAR 모형을 개발하였다. HAR 모형은 시차(lag)를 개별적으로 나열하는 대신, 단기(1일), 중기(5일), 장기(22일) 누적 평균 실현분산(Realized Volatility, RV)을 입력 변수로 사용한다. 이를 통해 단 네 개의 모수(parameter)만으로도 복잡한 자기상관 구조를 효과적으로 근사한다는 장점이 있다.


$$\log RV_{h,t+h} = \beta_0 + \beta_d \log RV_{d,t} + \beta_w \log RV_{w,t} + \beta_m \log RV_{m,t} \quad (7)$$

여기에서 (RV_d, RV_w, RV_m) 는 1일, 5일, 22일에 걸친 변동성 대리변수이다. HAR 모형은 구조적 단순성에도 불구하고 변동성의 장기 의존 구조를 효과적으로 포착하여 변동성 연구의 대표적인 벤치마크로 자리 잡았다.

2.2.2. LSTM

순환신경망(Recurrent Neural Network, RNN, Rumelhart et al., 1986)은 시퀀스 데이터의 시간적 의존성을 학습하기 위해 은닉 상태(hidden state) h_t 를 시점 간 재귀적으로 전파하는 구조를 갖는다. 그러나 RNN은 역전파 과정에서 기울기가 시간 축을 따라 지수적으로 감소하거나(기울기 소실, vanishing gradient) 지수적으로 증가하는(기울기 폭주, exploding gradient) 문제로 인해, 긴 시퀀스 학습이 실질적으로 어렵다는 한계가 지적되어 왔다.

LSTM(Hochreiter & Schmidhuber, 1997)은 이러한 한계를 해결하기 위해 설계된 구조이다. LSTM의 핵심 아이디어는 은닉 상태와 별도로 셀 상태(cell state) c_t 를 두고, $[0, 1]$ 구간의 출력값을 갖는 시그모이드 활성화 함수를 통해 셀 상태의 정보를 선택적으로 보존·삭제·갱신하는 것이다. Gers et al. (2000)이 망각 게이트(forget gate)를 도입한 이후, LSTM은 망각·입력·출력 게이트 및 후보 기억 상태(candidate cell state)로 구성된 표준 구조로 정착하였다.



<그림 1> LSTM 셀의 내부 구조.

그림 1의 LSTM 셀은 시점 t 에서 다음과 같이 계산된다.

$$f_t = \sigma(W_f[h_{t-1}, x_t] + b_f) \quad (8)$$

$$i_t = \sigma(W_i[h_{t-1}, x_t] + b_i) \quad (9)$$

$$\tilde{c}_t = \tanh(W_c[h_{t-1}, x_t] + b_c) \quad (10)$$

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t \quad (11)$$

$$o_t = \sigma(W_o[h_{t-1}, x_t] + b_o) \quad (12)$$

$$h_t = o_t \odot \tanh(c_t) \quad (13)$$

여기서 f_t, i_t, o_t 는 각각 망각·입력·출력 게이트, $\tilde{c}_t$ 는 후보 기억 상태를 나타낸다. $\sigma(\cdot)$ 은 시그모이드 활성화 함수, $\tanh(\cdot)$ 는 하이퍼볼릭 탄젠트 활성화 함수, $\odot$ 은 원소별 곱(Hadamard product)이다. 또한 W 와 b 는 각 구성 요소의 가중치 행렬과 편향 벡터를 나타내며, $[h_{t-1}, x_t]$ 는 은닉 상태와 입력 벡터의 결합(concatenation)을 의미한다. 식 (11)의 망각 게이트 f_t 가 1에 가까울 때 과거 셀 상태가 보존되고 0에 가까울 때 폐기되어, 시계열 장기 의존 구조를 선택적으로 보존하거나 제거할 수 있다.

LSTM은 자연어 처리, 음성 인식 등 시퀀스 학습 문제에서 폭넓게 활용되어 왔으며, 금융 변동성

예측에 적용한 연구들도 다수 보고되었다(Bucci, 2020; Kim & Won, 2018). 해당 연구들은 LSTM이 변동성 시계열의 비선형 구조를 학습하여 예측에 유의미하게 활용될 수 있음을 보였다.

2.2.3. 예측 앙상블

각 모형의 예측 결과를 결합하여 단일 모형 대비 오차를 줄이고자 하는 예측 결합(forecast combination, 이하 앙상블)은 Bates and Granger (1969) 이래로 활발히 연구되어 왔다. 두 예측의 가중 평균이 개별 예측보다 작은 평균제곱오차(Mean Squared Error, MSE)를 갖기 위한 이론적 조건을 분석한 이 연구는, 두 예측 오차 간의 상관관계가 낮을수록 결합을 통한 분산 감소 효과가 커진다는 점을 확인하였다.

이후의 연구는 Bates and Granger (1969)가 제안한 역분산 가중을 다양한 오차 척도로 확장한 변형들을 발전시켜 왔으며(Timmermann, 2006), 본 연구에서 채택하는 성과 가중(performance-weighted) 결합 방식 역시 이러한 발전 형태 중 하나이다. 구체적으로 각 모형의 과거 예측 오차에 반비례하도록 가중치를 부여하는 적응적 특성을 지닌다.

$$w_i = \frac{1/e_i}{\sum_{j=1}^M 1/e_j} \quad (14)$$

여기서 e_i 는 모형 i 의 과거 예측 오차(MSE 등)이며, M 은 결합 대상이 되는 총 모형의 개수이다. 이러한 가중치 구조는 시장 국면 변화에 따라 상대적으로 우수한 성능을 보인 모형의 비중이 자동으로 조정되는 적응적 특성을 가진다.

본 연구에서 결합하는 HAR 모형과 LSTM 모형은 서로 다른 이론적 가정에 기반하고 있다. HAR 모형은 변동성을 단·중·장기 변동성 대리변수의 선형 회귀로 모형화하는 반면, LSTM은 선형성 가정 없이 데이터로부터 비선형 의존 구조를 직접 학습한다. 이처럼 매커니즘이 다른 두 모형은 서로 다른 시장 국면에서 오차를 발생시킬 가능성이 크며, 따라서 두 모형의 앙상블을 통해 단일 모형 대비 더욱 안정적이고 강건한(robust) 예측 성능을 기대할 수 있다.

2.2.4. Walk-Forward 교차 검증

머신러닝 모형의 성능 평가에서 일반적으로 사용되는 무작위 k -fold 교차검증은 시계열 데이터에 적용할 경우 미래 정보가 학습 구간에 노출되는 미래 참조 편향(look-ahead bias) 문제를 발생시킨다. 이는 모형이 실제 운영 환경에서는 알 수 없는 정보를 학습에 반영하게 함으로써, 평가 구간(Out-of-Sample, OOS) 성능을 과대 평가하는 결과로 이어진다.

이러한 한계를 극복하기 위해 금융 시계열 예측에서는 학습 구간(In-Sample, IS)과 평가 구간(OOS)을 시간 순서대로 분리하고, 시점을 일정 간격으로 전진시키며 반복 평가하는 Walk-Forward 교차

검증 방식이 활용되어 왔다. 그러나 종속변수가 미래 구간으로 정의되는 경우(본 연구의 경우 향후 21 영업일 수익률 표준편차), IS의 마지막 시점이 포함하는 예측 타겟(forward target)이 OOS 구간의 예측 변수와 시간적으로 중첩되어 잔여 정보가 누설되는 문제(data leakage)가 발생하게 된다.

López de Prado (2018)는 이와 같은 잔여 정보 누설을 차단하기 위해 퍼징(Purging)과 엠바고(Embargo) 절차를 결합한 확장된 Walk-Forward 구조를 제안하였다. 퍼징은 IS 종료 직후 타겟 윈도우가 OOS와 겹치는 일정 구간의 표본을 학습에서 배제함으로써 타겟의 시간적 중첩으로 인한 왜곡을 제거하고, 엠바고는 OOS 시작 지점 직전에 추가 안전구간(embargo window)을 두어 시계열 종속변수의 자기상관(autocorrelation)이 충분히 감소한 이후에 OOS 평가를 시작하도록 통제한다.

2.3. 블랙-리터만과 변동성 예측의 결합

변동성 예측 결과를 BL의 뷰로 활용하는 시도는 머신러닝 기반 수익률 예측 연구에 비해 상대적으로 미진한 편이었다. Pyo and Lee (2018)는 변동성 예측을 BL 뷰로 직접 활용한 선행 연구이며, 본 연구의 출발점에 해당한다. 해당 선행 연구는 (i) 종목별 변동성 예측, (ii) 예측 결과를 활용한 BL 뷰로 결합, (iii) 결합된 사후 기대수익률에 기반한 포트폴리오 비중 최적화의 세 단계로 전개된다.

Pyo and Lee (2018)는 KOSPI 200 종목 각각에 대해 직전 10개월의 월별 변동성을 입력 변수로 활용하여 익월 변동성을 예측한다. 변동성 예측 모형으로 ANN, 가우시안 프로세스 회귀(Gaussian Process Regression, GPR), 서포트 벡터 회귀(Support Vector Regression, SVR), 그리고 GARCH 모형을 비교·평가하였으며, 예측 편차 측면에서 가장 안정적인 성능을 보인 ANN을 최종 예측 모형으로 채택하였다.

변동성 예측 결과를 기반으로 종목을 저변동(변동성 하위 30%)·고변동(변동성 상위 30%) 두 그룹으로 분류한 후, 투자자 뷰 $\mathbf{p}$ 의 개별 요소 p_i^{mcap} 은 다음과 같이 매수-매도(long-short) 형태로 구성된다.

$$p_i^{mcap} = \begin{cases} +\frac{mcap_i}{\sum_{j \in \mathcal{L}} mcap_j}, & \text{종목 } i \in \mathcal{L} \text{ (저변동 그룹, 하위 30\%)} \\ -\frac{mcap_i}{\sum_{j \in \mathcal{H}} mcap_j}, & \text{종목 } i \in \mathcal{H} \text{ (고변동 그룹, 상위 30\%)} \\ 0, & \text{otherwise} \end{cases} \quad (15)$$

여기서 $mcap_i$ 는 종목 i 의 시가총액이며, 각 그룹 내 시가총액 합계로 정규화하여 롱(Long) 측 합은 +1, 숏(Short) 측 합은 -1이 되는 자기자금조달(self-financing) 구조를 충족한다. 기대수익률 뷰 $\mathbf{q}$ 는 Fama-French 3팩터 모형(Fama-French 3-factor model, FF3, Fama & French, 1993)의 회귀 추정치와 $\mathbf{p}$ 의 결합으로 산출된다.

$$\hat{r}_i = \alpha + \beta_{mkt}(r_{mkt} - r_f) + \beta_{smb} \cdot SMB + \beta_{hml} \cdot HML \quad (16)$$

$$q = \mathbf{p}\hat{\mathbf{r}} \quad (17)$$

뷰 신뢰도 ω 는 직전 시점에서 뷰의 예측 수익률과 실현 수익률 차이의 분산으로 정의된다.

$$\omega = \text{var}(\mathbf{p}_{t-1}\hat{\mathbf{u}}_{t-1} - \mathbf{p}_{t-1}\mathbf{u}_{t-1}) \quad (18)$$

이는 뷰의 신뢰도를 직전 시점의 데이터로부터 경험적으로 추정하는 방식이다.

이렇게 구성된 $(\mathbf{p}, q, \omega)$ 를 BL의 사후 기대수익률 μ_{BL} 과 공분산 Σ_{BL} (식 (4), (5))에 대입하여 식 (6)으로부터 최종 포트폴리오 자산 배분 비중을 산출한다.

KOSPI 200 종목을 대상으로 한 실증 분석에서 BL 기반 포트폴리오는 샤프 비율 0.70을 달성하여 시가총액 가중 포트폴리오(0.36) 및 KOSPI 200 지수(0.59) 대비 우위를 보였다. 이는 변동성 예측을 BL 뷰로 활용하는 접근의 실증적 근거를 제시하였다.

3. 방법론


3.1. 전체 파이프라인

본 연구는 앞서 2.3절에서 서술한 Pyo and Lee (2018)의 분석 프레임워크를 기반으로 하되, 다음 두 가지 핵심적인 측면에서 본 연구의 차별성을 확보한다.

첫째, 금융 시계열의 특성을 반영할 수 있는 예측 모형의 고도화이다. Pyo and Lee (2018)에서 활용된 ANN은 시계열 구조에 특화되지 않은 단순 전방향(Feed-forward) 신경망 구조라는 한계가 있으므로, 본 연구는 이를 2.2절에서 언급한 LSTM과 HAR 모형의 앙상블 구조로 대체한다. 다만, 선행 연구와의 통제된 비교를 위해 ANN을 동일한 환경에서 기준 모형으로 함께 평가한다.

둘째, BL 뷰 설정 슬롯의 확장이다. Pyo and Lee (2018)은 포트폴리오 뷰 $\mathbf{p}$, 기대수익률 뷰 q , 뷰 신뢰도 ω , 사전 분포 $\mathbf{w}_{mkt}$ 를 단일 설정으로 고정한 반면, 본 연구는 이 네 축을 각각 복수의 후보로 정의한 후 모든 조합을 결합한 90개의 파라미터 슬롯 조합을 구성하여 체계적으로 비교·평가한다. 본문에서는 주요 45개 슬롯 결과를 중심으로 보고하며, 전체 90개 조합에 대한 실증 분석 결과는 부록 B에 수록한다.

본 연구의 실증 분석은 미국 대형주 시장의 S&P 500 지수 편입 종목을 대상으로 수행한다. 이는 국내 시장에 국한되었던 선행 연구를 넘어, 종목 수와 섹터 다양성이 큰 시장에서의 모형 강건성(robustness)을 확인하기 위함이다.



<그림 2> 본 연구의 전체 분석 파이프라인.

전체 연구 파이프라인은 그림 2과 같이 네 단계로 구성된다. (1) LSTM-HAR 양상블 모형으로 자산별 변동성 $\hat{\sigma}_t$ 를 예측한 후, 하위 및 상위 30% 구간을 각각 저변동·고변동 종목으로 분류한다. (2) $\hat{\sigma}_t$ 는 BL 뷰 파라미터 ($\mathbf{p}, \mathbf{q}, \omega$) 구성에 활용되며, 사전 분포 $\mathbf{w}_{mkt}$ 는 $\hat{\sigma}_t$ 와 독립적인 경로로 산출된다. 이때 네 슬롯은 각각 3·5·2·3개의 후보를 가지고 있어 총 90개 조합을 형성한다. (3) 시장 균형 사전

분포와 투자자 전망 분포를 베이지안 매커니즘으로 결합하여 (4) 사후 분포 (μ_{BL}, Σ_{BL})를 도출하고, MVO를 통해 저변동 포트폴리오 최적 자산 배분 가중치 $\mathbf{w}^*$ 를 산출한다. 이어지는 절에서는 각 단계의 구체적인 방법론을 기술한다.

3.2. 변동성 예측

본 절에서는 앞서 2.2절에서 살펴본 HAR 모형과 LSTM 모형, 그리고 이를 결합하는 예측 앙상블 방법론과 Walk-Forward 구조를 본 연구에 적용한 구체적인 구현 방식을 기술한다.

3.2.1. 종속변수와 입력변수

본 연구는 시점 t 기준 향후 21영업일(약 1개월) 수익률의 표준편차를 종속변수로 사용한다. 21일 예측 윈도우(window) 길이는 포트폴리오 리밸런싱 주기(월 1회)와 일치하도록 동기화되며, 일별 로그 수익률 r 을 이용하여 다음과 같이 정의된다.

$$y_t = \log(\text{std}(r_{t+1}, \dots, r_{t+21})) \quad (19)$$

정의된 종속변수에는 로그 변환을 적용한다. 로그 변동성은 근사적으로 정규분포를 따르므로, MSE를 평가지표로 사용할 때 학습 안정성을 확보할 수 있다는 장점이 있다. 또한 로그 공간에서 학습하기 때문에 지수 역변환을 거친 후에도 항상 양수(positive) 예측이 보장된다. 모형 성능 평가에는 RMSE(Root Mean Squared Error)를 주된 지표로 사용하며, 보조 지표로 스피어만(Spearman) 상관계수와 Hit rate를 함께 확인하여 예측의 방향성과 순위 보존 능력을 종합적으로 평가한다.

입력변수는 1일·5일·22일 세 가지 시간 척도의 변동성 대리변수를 활용하며, 이는 일별 종가수익률 제곱으로 산출한다.

$$RV_{d,t} = r_t^2 \quad (20)$$

$$RV_{w,t} = \frac{1}{5} \sum_{s=0}^4 r_{t-s}^2 \quad (21)$$

$$RV_{m,t} = \frac{1}{22} \sum_{s=0}^{21} r_{t-s}^2 \quad (22)$$

이는 Corsi (2009)의 원본 HAR 모형이 사용하는 일내 고빈도 실현변동성을 일별 종가 기반 대리변수로 근사한 형태이다. 본 연구의 분석 대상인 S&P 500 종목군(약 617 종, 2010–2025) 전반에 대해 일관된 일내 고빈도 데이터를 확보하기 어렵다는 현실적인 제약을 고려하여, 이와 같은 일별 종가 기반 근사를 채택하였다.

HAR 모형은 위 세 가지 항만을 입력으로 사용하는 반면, LSTM 모형은 세 항의 로그 변환 값에 추가로 시장의 미래 변동성 기대를 반영하는 변동성 지수(CBOE Volatility Index, VIX, Whaley, 2009)

의 로그 변환 값을 포함하여 총 4 차원의 입력 벡터를 구성한다.

$$\mathbf{x}_t = [\log RV_{d,t}, \log RV_{w,t}, \log RV_{m,t}, \log VIX_t]^\top \quad (23)$$

LSTM 모형에 VIX 지수를 추가한 이유는 S&P 500 옵션 시장에 내재된 미래 변동성 기대가 개별 종목의 향후 실현 변동성을 예측하는 데 유용한 정보를 제공할 것이라는 가정에 기반한다.

모형의 최종 출력값 $\hat{y}_t$ 는 식 (19)에 따라 일별 로그 변동성의 표준편차이다. BL의 시장 균형 수익률 π 와 공분산 행렬 Σ 가 모두 연환산 단위로 정의되므로, 변동성 예측 뷰 역시 동일한 단위로 맞추기 위해 지수 역변환 후 연환산 과정을 거친다.

$$\hat{\sigma}_t = \exp(\hat{y}_t) \times \sqrt{252} \quad (24)$$

여기서 $\sqrt{252}$ 는 일간 표준편차를 연간 표준편차로 환산하는 처리이다.

3.2.2. 예측 모형

본 절에서는 변동성 예측 모형으로 활용된 LSTM과 HAR, 그리고 두 모형의 앙상블 구조와 기준 모형인 ANN의 구체적인 구조 및 하이퍼파라미터 설정을 기술한다.

LSTM

LSTM 모형은 2.2.2절에서 살펴본 표준 LSTM 셀 구조(그림 1, 식 (8)–(13))를 1개의 은닉층(1-layer), 은닉 노드 수 32개, 드롭아웃 비율 0.3, 그리고 시퀀스 길이는 63영업일로 구성한다. 시퀀스 길이를 63영업일로 설정한 것은 약 3개월의 시간 척도에 해당하는 기간으로, 변동성 대리변수인 S&P 500 지수(SPY) 일별 수익률 제공 시계열의 자기상관이 lag 60 전후까지 통계적으로 유의하게 지속됨을 탐색적 데이터 분석(EDA)에서 확인한 결과에 근거한 선택이다. 개별 종목별로 자기상관 길이에 미세한 차이는 존재할 수 있으나, 모형의 통일성과 일관된 평가를 위해 전 종목에 동일하게 적용한다.

학습은 AdamW 옵티마이저(학습률 10^{-3} , 가중치 감쇠 10^{-3})와 MSE 손실함수를 사용하며, 최대 50 에포크(epoch) 동안 진행된다. 이 과정에서 과적합을 방지하기 위해 10 에포크 동안 검증 손실(validation loss)이 개선되지 않을 경우 학습을 중단하는 조기 종료(early stopping) 규칙을 적용하며, 배치 크기(batch size)는 64로 설정한다. 입력 시퀀스 $\mathbf{X}_{t-L+1}, \dots, \mathbf{X}_t$ ($L = 63$)에 대한 최종 로그 변동성 예측은 다음과 같다.

$$\hat{y}_t^{\text{LSTM}} = f_{\text{LSTM}}(\mathbf{X}_{t-L+1}, \dots, \mathbf{X}_t) \quad (25)$$

HAR

HAR 모형은 2.2.1절의 식 (7)의 구조를 본 연구의 일별 변동성 대리변수에 적용한다. 회귀계수

$(\beta_0, \beta_d, \beta_w, \beta_m)$ 는 각 IS 구간에서 OLS(Ordinary Least Squares) 방식으로 추정하며, OOS 구간에 대한 예측값은 추정된 회귀계수와 OOS 입력 변수의 선형 결합으로 다음과 같이 산출한다.

$$\hat{y}_t^{\text{HAR}} = \beta_0 + \beta_d \log RV_{d,t} + \beta_w \log RV_{w,t} + \beta_m \log RV_{m,t} \quad (26)$$

성과 가중 앙상블(Performance-Weighted Ensemble)

최종 변동성 예측값은 앞서 2.2.3절에서 제시한 성과 가중 결합 방식(식 14)을 LSTM과 HAR 두 모형에 적용하여 산출한다. 폴드(fold) k 에서의 모형별 가중치는 직전 폴드 $k-1$ 의 OOS RMSE 역수에 비례하게 설계되었으며, 폴드 $k=0$ 에서는 사전 성능 정보가 없으므로 두 모형에 동일한 가중치 0.5를 부여한다.

$$w_k^{\text{LSTM}} = \frac{1/\text{RMSE}_{k-1}^{\text{LSTM}}}{1/\text{RMSE}_{k-1}^{\text{LSTM}} + 1/\text{RMSE}_{k-1}^{\text{HAR}}} \quad (27)$$

$$w_k^{\text{HAR}} = 1 - w_k^{\text{LSTM}} \quad (28)$$

최종 앙상블 변동성 예측값은 두 모형의 가중 평균이다.

$$\hat{y}_t^{\text{ens}} = w_k^{\text{LSTM}} \cdot \hat{y}_t^{\text{LSTM}} + w_k^{\text{HAR}} \cdot \hat{y}_t^{\text{HAR}} \quad (29)$$


두 모형의 개별 예측 성능 및 앙상블 결합을 통한 오차 감소 효과는 추후 4.1에서 비교 분석한다. 그림 3은 입력 변수부터 최종 BL 입력치 산출까지의 전체 흐름을 요약한다.

입력	모형	가중 결합	BL 입력
$\log RV_{d,t}, \log RV_{w,t}, \log RV_{m,t}, \log VIX_t$	→ LSTM ↘		
		$\hat{y}_t^{\text{ens}}$	→ $\hat{\sigma}_t$
$\log RV_{d,t}, \log RV_{w,t}, \log RV_{m,t}$	→ HAR ↗		

<그림 3> 성과 가중 앙상블 기반의 변동성 예측 흐름.

ANN (기준 모형)

본 연구는 2.3절의 Pyo and Lee (2018)의 ANN을 기준 모형으로 설정하여, 동일한 평가 환경 하에서 함께 평가한다. 해당 연구는 ANN의 세부 구조를 명시적으로 보고하지 않았으나, 금융 데이터 특성상 학습 표본 크기가 제한적이어서(60개월 윈도우 기준 유효 표본 약 50개) 과적합 위험이 크다는 점을 고려하였다. 이에 따라 학습 가능 파라미터 수(49개)가 학습 표본 수(약 50개)와 유사한 범위 내에 머물도록, 단일 은닉층 4개의 뉴런으로 구성된 소규모 구조로 재현하여 과적합 위험을 최소화하였다.(그림 4). 은닉층의 활성화 함수로는 ReLU를, 옵티마이저는 Adam을 사용하며, 과적합 방지를 위해 추가적으로 L_2 정규화($\alpha = 0.01$)를 적용하여 추정의 안정성을 보완하였다.




<그림 4> ANN 기준 모형의 구조.

Pyo and Lee (2018)의 원본 사양에 따라, ANN의 입력 변수는 직전 10개월의 월별 로그 변동성을, 출력 변수는 익월의 월별 로그 변동성을 사용한다. 각 월의 변동성은 해당 월말 기준 직전 21영업일 일별 수익률의 표준편차로 정의하여, LSTM 및 HAR 모형이 사용하는 향후 21영업일 변동성 (식 (19))과 동일한 일별 로그 변동성 단위로 산출되도록 하였다. 샘플링 주기(일별/월별)에 차이가 있으나 출력 단위가 동일하여 4.1절의 Walk-Forward 평가에서 직접 비교가 가능하다.

3.2.3. Walk-Forward 학습·평가

2.2.4절의 퍼징-엠바고 Walk-Forward 구조를 모든 변동성 모형(LSTM, HAR, 앙상블, ANN)의 학습 및 평가에 동일하게 적용한다. 각 폴드는 그림 5과 같이 IS 1,250 영업일(약 5년), 퍼징 21영업일, 엠바고 63영업일, OOS 21영업일의 네 가지 구간으로 구성되며, 매 21영업일 간격으로 전진 이동(rolling)한다.



<그림 5> Walk-Forward 슬라이딩 평가 구조 (IS 1,250 · Purging 21 · Embargo 63 · OOS 21 영업일).

IS 구간의 1,250영업일은 Pyo and Lee (2018)의 학습 윈도우(60개월)와 동일한 조건 하에서 비교하기 위해 설정하였다. 퍼징 구간의 21영업일은 종속변수의 미래 예측 윈도우(식 19)와 동일한 길이로 설정되었으며, IS 마지막 시점의 미래 타겟이 OOS 구간과 시간적으로 중첩되지 않도록 차단한다. 엠바고 구간의 63영업일은 앞서 정의한 LSTM 모형의 입력 시퀀스 길이(63영업일)와 일치하도록 설정하여, 변동성 자기상관이 충분히 감쇠한 이후에 OOS 평가를 시작하도록 제한한다.

3.3. 블랙-리터만 구조 및 슬롯

본 절에서는 앞서 2.1절의 BL 일반식(식 (1)–(6))에 등장하는 네 가지 입력 변수인 $\mathbf{w}_{mkt}$ (사전 분포), $\mathbf{p}$ (뷰 포트폴리오), q (뷰 기대수익률), ω (뷰 신뢰도) 각각에 대해 본 연구에서 비교·분석할 슬롯별 옵션을 정의한다. 2.3절의 Pyo and Lee (2018)가 각 입력 변수에 단일 설정을 채택한 반면, 본 연구는 3.2절의 변동성 예측 결과를 BL 구조에 어떻게 연결할지에 따라 각 입력을 옵션 집합으로 일반화하고, 그 곱집합(Cartesian product)을 슬롯 그리드로 정의한다.

3.3.1. 제안 슬롯

사전 분포 ($\mathbf{w}_{mkt}$)

균형 수익률 π (식 1) 계산에 사용하는 시장 비중 $\mathbf{w}_{mkt}$ 를 세 가지 방식으로 구성한다.

- $\mathbf{w}^{mcap}$: 시가총액 비중 가중. Pyo and Lee (2018)의 원안이며, CAPM의 균형 시장 포트폴리오 가정에 부합한다.
- $\mathbf{w}^{eq}$: 동일 가중. 유니버스 전체에 균등한 사전 정보를 부여한다.

- $\mathbf{w}^{\text{rp}}$: 직전 21영업일 실현 변동성의 역수($1/\sigma_{\text{realized}}$) 비중 가중. 저변동 종목에 더 큰 가중치를 배분하는 리스크 패리티(Maillard et al., 2010) 철학에 기반한다. 단, 사용하는 변동성은 LSTM 예측값이 아닌 전월의 실현 변동성이다.

뷰 포트폴리오 ($\mathbf{p}$)

$\mathbf{p}$ 벡터는 저변동 자산이 고변동 자산을 초과 성과할 것이라는 뷰를 인코딩한다. 각 리밸런싱 시점 t 에서 유니버스 내 종목을 앙상블 예측 변동성 $\hat{\sigma}_{i,t}$ 기준으로 오름차순 정렬 후, 하위 30%(저변동 그룹 $\mathcal{L}$)에 양(+)의 가중치, 상위 30%(고변동 그룹 $\mathcal{H}$)에 음(-)의 가중치를 부여하며, 나머지 40%는 0으로 처리한다. 롱 측 가중치의 합은 +1, 숏 측 가중치의 합은 -1로 정규화되어 $\sum_i p_i = 0$ 을 만족하며, 이는 자기자금조달(self-financing) 롱-숏 포트폴리오 뷰에 해당한다. 분류 임계값(상하위 30%)은 Pyo and Lee (2018)의 설정을 따르며, 그룹 내 가중 방식은 본 연구에서 세 가지로 일반화한다.

- $\mathbf{p}^{\text{mcap}}$: 시가총액 비례 가중. Pyo and Lee (2018)의 원안으로, 각 그룹 내 시가총액 합계로 정규화한다. 식 (15)와 동일한 식을 사용한다.
- $\mathbf{p}^{\text{eq}}$: 동일 가중. 각 그룹 내 모든 종목에 $+1/|\mathcal{L}|$ (롱 측) 또는 $-1/|\mathcal{H}|$ (숏 측) 을 배분하여, 시가총액 집중에 따른 편향을 제거하고 변동성 분류 신호를 균등하게 반영한다.
- $\mathbf{p}^{\text{rp}}$: 역변동성 가중. 그룹 내 종목에 예측 변동성의 역수에 비례한 비중을 배분한다.

$$p_i^{\text{rp}} = \begin{cases} +\frac{1/\hat{\sigma}_i}{\sum_{j \in \mathcal{L}} 1/\hat{\sigma}_j}, & i \in \mathcal{L} \\ -\frac{1/\hat{\sigma}_i}{\sum_{j \in \mathcal{H}} 1/\hat{\sigma}_j}, & i \in \mathcal{H} \\ 0, & \text{otherwise} \end{cases} \quad (30)$$

- 분류(상하위 30% 선택) 단계에서는 모형 예측값의 순위 정보를, 가중(그룹 내 배분) 단계에서는 크기 정보를 각각 활용한다는 점에서, $\mathbf{p}^{\text{rp}}$ 는 모형의 예측값이 이중으로 활용되는 구조다. 이러한 구조는 변동성 예측 신호를 포트폴리오에 적극적으로 반영할 수 있다는 한편, 모델의 추정오차가 누적될 위험을 수반한다.

뷰 기대수익률 (q)

q 는 저변동-고변동 그룹 간 기대수익률 스프레드로, 본 연구는 다섯 가지 슬롯을 비교한다. 다섯 가지 슬롯은 q 를 결정하는 정보 채널에 따라 다음 세 범주로 구분된다.

- 시장 위험회피도(λ_q) 기반: $q^{\text{lam}}, q^{\text{raw}}, q^{\text{inv}}$ — SPY 초과수익과 시장 분산으로 추정된 매크로 위험회피도를 신호로 사용한다.

- **예측 변동성($\Delta\hat{\sigma}$) 기반:** q^{vsp} — 고/저변동 그룹의 예측 변동성 격차를 q 에 직접 반영한다.
- **Fama-French 3팩터 모형(FF3) 기반:** q^{ff3} — Pyo and Lee (2018)의 원안에 해당하는 본 연구의 앵커 슬롯이다.

앞의 두 범주에 속하는 4개의 슬롯은 공통 기준값 $q_0 = 0.003$ 을 시장 신호로 동적 조정하는 반면, q^{ff3} 은 종목별 팩터 회귀 결과를 $\mathbf{p}$ 와 결합하여 q 를 직접 산출한다.

기준값 q_0 설정. 4개 동적 조정 슬롯의 기준값 $q_0 = 0.003$ (월 0.3%)은 저위험 이상현상 실증 문헌의 보고치를 보수적으로 반영한 값이다. Frazzini and Pedersen (2014)는 미국 주식 표본에서 BAB(Betting Against Beta) 팩터의 월 평균 초과수익을 약 0.55–0.70% 수준으로 보고하며, Baker et al. (2011)와 Blitz and van Vliet (2007) 역시 저변동 long-short 전략의 월 수익이 0.4–0.7% 범위임을 확인한다. 본 연구는 예측 모형의 오판 가능성을 감안해 실증치의 약 절반인 0.3%를 기준값으로 채택한다.

λ_q 기반 슬롯. 동적 조정에 사용하는 시장 위험회피도 λ_q 는 π 계산용 고정 $\lambda = 2.5$ 와 별개로, 매 시점 다음과 같이 추정한다.

$$\lambda_q = \text{clip}(\bar{r}_{SPY}^{\text{ex}}/\sigma_{\text{mkt}}^2, 0.5, 10.0) \quad (31)$$

여기서 $\text{clip}(x, a, b) = \min(\max(x, a), b)$ 는 x 의 값을 $[a, b]$ 범위로 상·하한을 제한하는 함수이며, $\bar{r}_{SPY}^{\text{ex}}$ 는 SPY 평균 초과수익률, σ_{mkt}^2 는 시장 수익률 분산, $\bar{\lambda}_q$ 는 훈련 기간 내 λ_q 의 평균이다.

- q^{lam} : λ_q 비례 조정. 시장이 안정적(λ_q 상승)일수록 q 를 강화하고, 불안정(λ_q 하락)할수록 약화한다.

$$q^{\text{lam}} = q_0 \times \text{clip}(\lambda_q/\bar{\lambda}_q, 0.1, 3.0) \quad (32)$$

- [0.1,3.0] 범위의 상·하한 제약은 q 가 q_0 의 10% 미만으로 소멸하거나 3배를 초과하여 증폭되는 것을 방지하기 위한 실용적 제약이며, q^{inv} 와 q^{vsp} 에도 동일하게 적용된다.
- q^{raw} : 상·하한 제약 적용 이전의 λ_q 사용. SPY 하락으로 $\lambda_q^{\text{raw}} < 0$ 이면 q 가 0으로 수렴하여, 시장 방향에 따라 뷰가 자연 소멸된다.

$$q^{\text{raw}} = \max(0, q_0 \times \lambda_q^{\text{raw}}/\bar{\lambda}_q) \quad (33)$$

- q^{inv} : λ_q 역수 조정. 불안정 국면에서 q 를 강화하여 저변동 방어 전략을 키우는, q^{lam} 과 반대 방향으로 작동한다.

$$q^{\text{inv}} = q_0 \times \text{clip}(\bar{\lambda}_q/\lambda_q, 0.1, 3.0) \quad (34)$$

예측 변동성 기반 슬롯. q^{vsp} 는 모형의 예측 변동성 격차를 훈련 기간 중앙값으로 정규화하여 q 의 크기를 조정한다. λ_q 분류가 매크로 시장 신호를 사용하는 반면, q^{vsp} 는 LSTM 예측 변동성을 q 에 직접 반영한다.

$$q^{vsp} = q_0 \times \text{clip}(\Delta\hat{\sigma}_t / \text{median}(\Delta\hat{\sigma}_{\text{train}}), 0.1, 3.0) \quad (35)$$

여기서 $\Delta\hat{\sigma}_t = \frac{1}{|H|} \sum_{i \in H} \hat{\sigma}_{i,t} - \frac{1}{|L|} \sum_{i \in L} \hat{\sigma}_{i,t}$ 이며, H, L 의 정의에 의해 $\Delta\hat{\sigma}_t > 0$ 이 보장된다. 이 값은 매 리밸런싱 시점마다 시장 상황에 따라 크게 달라질 수 있어, 훈련 기간 내 $\Delta\hat{\sigma}_t$ 시계열의 중앙값으로 나누어 정규화함으로써 위기 구간 등 극단적으로 커지는 시점이 기준값에 미치는 영향을 억제하였다.

팩터 모형 기반 슬롯. Pyo and Lee (2018)는 FF3 회귀로 q 를 산출한다는 방향만 제시하고 팩터 프리미엄 산정 방식의 세부는 명시하지 않아, 본 연구는 단기 추정의 불안정성을 피하기 위해 훈련 윈도우(60개월) 내 팩터 평균을 다음 달 기대 팩터 프리미엄으로 사용하는 방식(Cochrane, 2005; Fama & MacBeth, 1973)으로 구현하였다. 종목별 FF3 롤링 회귀로 추정된 기대수익률 $\hat{r}_i$ 와 $\mathbf{p}$ 의 결합으로 q 를 산출하며, 훈련 기간 내 데이터만 사용하므로 미래 참조 편향이 없다. 이 구현이 Pyo and Lee (2018)의 FF3 방식에 해당하는 본 연구의 앵커 슬롯이다.

$$q^{\text{ff3}} = \mathbf{p}\hat{\mathbf{r}}, \quad \hat{r}_i = \hat{\alpha}_i + \hat{\beta}_i^{\text{mkt}} \bar{f}_{\text{mkt}} + \hat{\beta}_i^{\text{SMB}} \bar{f}_{\text{SMB}} + \hat{\beta}_i^{\text{HML}} \bar{f}_{\text{HML}} \quad (36)$$

여기서 $\bar{f}_k$ 는 훈련 윈도우 내 팩터 k 의 평균값이며, SMB(Small Minus Big)와 HML(High Minus Low)은 FF3 표준 팩터다.

뷰 신뢰도 (ω)

ω 는 사전 균형 수익률 대비 투자자 뷰의 신뢰도를 결정하며, 본 연구는 다음 두 가지 설정을 비교한다.

- ω^{he} (He-Litterman 방식): 뷰 포트폴리오의 사전 분산에 비례하여 불확실성을 설정하는 BL 문헌의 표준 방식이다 (He & Litterman, 1999).

$$\omega^{\text{he}} = \tau \mathbf{p} \Sigma \mathbf{p}^T \quad (37)$$

- ω^{err} (전월 예측 오차 기반): 각 시점 t 에서 전월 ($t-1$)의 뷰 포트폴리오 예측 수익률과 실현 수익률 간 오차 제곱으로 불확실성을 추정하며, Pyo and Lee (2018)의 방식을 따른다.

$$\omega^{\text{err}} = (q_{t-1} - \mathbf{p}_{t-1} \mathbf{r}_{t-1})^2 \quad (38)$$

- 여기서 $\mathbf{r}_{t-1}$ 은 $t-1$ 시점의 실현 수익률 벡터다. 전월 뷰 예측이 크게 빗나간 시점에서 불확실성이 자동으로 증가하는 자기교정적 구조이며, 첫 달은 ω^{he} 로 초기화한다.

이 구현은 Pyo and Lee (2018)가 제시한 일반형 식 (18)의 한 가지 해석에 해당한다. 원 식 $\omega = \text{var}(\mathbf{P}_{t-1}\hat{\boldsymbol{\mu}}_{t-1} - \mathbf{P}_{t-1}\boldsymbol{\mu}_{t-1})$ 은 모두 단일 시점 $t-1$ 로 평가되어 있어, var 이 (i) $t-1$ 까지의 과거 시계열에 대한 표본분산인지, (ii) 단일 시점의 제곱 편차인지, (iii) 종목 단면 분산인지가 수학적으로 명확히 규정되지 않는 모호성이 존재한다. 본 연구는 BL 산출의 단순성과 직관성을 확보하기 위해 (ii)의 해석을 채택하였다. 결과적으로 ω^{err} 는 엄밀한 분산 추정량이 아닌 직전 시점 제곱 오차 추정치이나, 전월 오차 크기에 비례해 뷰 신뢰도가 자동 조정되는 자기교정 효과는 동일하게 보존된다.

3.3.2. Walk-Forward 및 최적화

포트폴리오 비중은 월별 리밸런싱 시점마다 시간 순서를 따라 산출하는 Walk-Forward 슬라이딩 방식으로 추정한다. 변동성 예측 단계(3.2절)와 달리 현재 시점의 가중치를 산출하므로, 별도의 퍼징·엡마고 구간 없이, 매 리밸런싱 시점에서 직전 60개월 데이터를 사용한다. 각 리밸런싱 시점 t (월 1회)에서 다음 절차를 수행한다.

1. 직전 60개월 일별 로그 수익률에 Ledoit-Wolf 수축 추정량 (Ledoit & Wolf, 2004)을 적용하여 공분산 행렬 $\boldsymbol{\Sigma}_t$ 를 산출한다. 이는 BL 프레임워크의 사전·사후 분포 계산에 사용되며, 변동성 예측 모형의 출력($\hat{\sigma}_{i,t}$)과는 독립적으로 산출된다.
2. 해당 시점의 시장 비중 $\mathbf{w}_{mkt,t}$ 와 고정 위험회피도 $\lambda = 2.5$ 로 식 (1)에 따라 균형 수익률 $\boldsymbol{\pi}_t$ 를 계산한다.
3. 앙상블 모형(또는 ANN 기준 모형)의 예측 변동성 $\hat{\sigma}_{i,t}$ 로 $\mathbf{p}_t$ 를 구성하고, 슬롯 설정에 따라 q_t 와 ω_t 를 산출한다.
4. 식 (4), (5)에 따라 BL 사후 분포의 평균 $\boldsymbol{\mu}_{BL,t}$ 와 공분산 $\boldsymbol{\Sigma}_{BL,t}$ 를 계산한다.
5. 식 (6)에 단일 종목 비중 상한 $w_i \leq 0.10$ 제약을 추가한 형태로 최적화하여 포트폴리오 비중을 산출한다.

비중 상한 10%는 극단적 집중 투자를 방지하기 위한 운용상 제약이다. 또한 데이터의 가용성을 확보하기 위해 각 리밸런싱 시점에서 훈련 윈도우(60개월) 내 일별 수익률 데이터가 90% 이상 존재하는 종목만 유효 유니버스로 선별한다. 거래비용은 편측 20bp를 적용하며, 월별 실제 비중 변화량 $\sum_i |\Delta w_{i,t}|$ 에 비례하여 차감한다. 이는 S&P 500 구성 종목의 실제 매매 스프레드 대비 보수적인 설정으로, ω^{err} 슬롯의 예측오차 기반 신뢰도 조정이 고변동 구간에서 회전율을 높일 수 있다는 점을 고려한 것이다. 무위험 수익률은 미국 3개월 국채 수익률을 사용하며, 샤프 비율 산출 시 초과수익률 계산에 적용한다.

3.3.3. 평가 방법론

전체 분석 기간은 2010년 1월부터 2025년 12월까지(192개월)이며, 시장 국면에 따라 성과가 크게 달라질 수 있으므로 전체 기간 평가와 국면별 성과 분해를 병행한다.

구체적인 국면 분류 과정은 부록 A에 상세히 기술되어 있으며, 본 연구는 Hidden Markov Model(HMM, Hamilton, 1989) 기반의 통계적 구조전환점 탐지와 금융 이벤트 도메인 지식을 결합하여 네 개의 비중첩 구간을 식별하였다(표 1).

각 국면 및 전체 기간에 대한 성과지표로는 샤프 비율, Sortino 비율, 최대 낙폭(Maximum Drawdown, MDD)을 산출한다. 이와 같은 국면별 성과 분해를 통해 앙상블 기반 BL 포트폴리오의 ANN 대비 우위가 특정 시장 국면에 의존하는지, 혹은 전 국면에 걸쳐 일관되게 유지되는지를 체계적으로 검증한다. 이를 위해 앙상블 모형과 ANN 기준 모형은 동일한 90개 슬롯 조합에 대해 1:1 대응 비교하며, 슬롯 구성은 두 모형 간 완전히 동일하게 유지한다.

<표 1> 분석 국면(regime) 구분 및 시기별 특성

국면	기간	기간(개월)	특성
R1 (회복기)	2010.01–2012.06	30	Post-GFC 회복, 유럽 재정위기
R2 (확장기)	2012.07–2019.12	90	장기 Bull Market, 저변동
R3 (위기기)	2020.01–2023.06	42	COVID-19, 2022 약세장
R4 (정상화)	2023.07–2025.12	30	AI 주도 랠리
전체	2010.01–2025.12	192	—

4. 실증 분석

본 연구의 실증 분석은 2010년 1월부터 2025년 12월까지 총 16년(192개월) 동안 미국 S&P 500 지수에 편입된 종목을 대상으로 수행한다. 종목 유니버스는 분석 기간 중 한 번이라도 S&P 500에 포함되었던 833개 종목에서 출발하였다. 이 중 야후 파이낸스(Yahoo Finance)를 통해 일별 가격 데이터 확보가 가능한 617개 종목을 최종 분석 대상으로 선정하였으며, 데이터가 제외된 종목들은 상장 폐지나 인수합병 등으로 인한 가용성의 한계에 기인한다. 특히 매 리밸런싱 시점마다 해당 시점의 실제 S&P 500 편입 종목만을 포트폴리오에 포함시키는 시점별 멤버십 필터링을 적용함으로써 생존 편향을 완화하였으나, 데이터 가용성 한계로 인한 편향을 완전히 배제할 수 없다. 그 외 결측치 처리, 거래비용, 자산별 비중 상한 등 구체적인 포트폴리오 운용 조건은 3.3.2절에서 기술한 바와 같다.

분석에 사용된 주가, 시가총액, VIX 지수, 무위험 수익률 데이터는 야후 파이낸스에서 수집하였으며, FF3 시계열 데이터는 케네스 프렌치(Kenneth French) 데이터 라이브러리를 활용하였다. 또한, 시점별 S&P 500 편입 종목 정보는 위키피디아(Wikipedia)의 S&P 500 변경 이력을 바탕으로 구축

하였다. 본 절은 변동성 예측 성능(4.1절), 기준 슬롯의 1차원 변형(4.2절), 슬롯 차원별 주변 분포(4.3절), 외부 벤치마크 대비 성과(4.4절) 순으로 실증 분석 결과를 제시한다.

4.1. 변동성 예측 성능

표 2는 LSTM 모형과 HAR 모형, 두 모형의 앙상블, 그리고 ANN 기준 모형의 변동성 예측 성능을 전체 기간과 4개 국면별로 비교한 결과이다. 모든 지표는 본 연구의 BL 모형이 매월 단면(cross-sectional) $\hat{\sigma}_t$ 을 입력으로 받는 것을 고려하여, 월별 단면 단위로 RMSE, Spearman 순위상관, Hit Rate를 산출한 뒤 해당 기간 내 평균하여 보고한다. 통계적 유의성 검정에는 정상 블록 부트스트랩(Stationary Block Bootstrap, SBB, Politis & Romano, 1994)을 사용하였으며, 효과크기는 대응된 손실 차의 평균을 표준편차로 나눈 표준화 통계량인 코헨의 d_z (Cohen's d_z , Cohen, 1988)로 함께 보고한다. R2를 제외한 나머지 국면의 표본 크기가 30 ~ 42개월로 작아 디볼드-마리아노(Diebold-Mariano, Diebold & Mariano, 1995) 검정의 점근 정규성 가정과 자기상관-이질분산 일관 분산(Heteroscedasticity-Autocorrelation Consistent, HAC) 직접 검정의 정확도에 한계가 있어, 시계열 자기상관 구조를 보존하면서 분포 가정이 필요 없는 블록 부트스트랩이 본 구조에 더 적합하다고 판단하였다. 본 연구에서 SBB는 이하 4.2-4.4절 및 부록 B에서도 페어 부트스트랩 기반으로 일괄 적용되며, 샤프 비율 차이 검정에는 Ledoit & Wolf(2008)의 부트스트랩 검정 프레임워크를 함께 적용한다(상세 검정 절차는 4.2절 참조). 별표는 모든 표에 일괄 적용한다(별표: * $p < .05$, ** $p < .01$, *** $p < .001$).

먼저 단독 모형 성능을 보면, LSTM과 HAR 모형 모두 ANN 기준 모형 대비 대부분의 지표와 국면에서 통계적으로 유의한 우위를 보여 두 모형의 유용성을 확인하였다. 두 모형 간의 직접 비교에서는 HAR 모형이 모든 평가지표에 걸쳐 LSTM 대비 일관된 우위를 보였다. 전체 기간 기준 Spearman 순위상관에서 HAR(0.6795)은 LSTM(0.6490) 대비 0.031의 격차($p < .001$, $d_z = +0.65$)를, 상위 30% Hit Rate에서 0.025의 격차(0.6598 vs 0.6349, $p < .001$, $d_z = +0.74$), RMSE 측면에서도 동일 방향의 격차(0.3603 vs 0.3907, $p < .05$, $d_z = +0.17$)가 관찰되며, 이러한 우위는 4개 국면 전반에 걸쳐 일관되게 관찰된다. 이는 변동성 동학에서 일별·주별·월별 RV의 선형 결합이 지배적인 예측 신호로 작용함을 시사하며, 본 LSTM 구현(4채널 입력·단일 은닉층)이 갖는 비선형 학습 능력이 본 표본 규모에서 추가적 예측력으로 충분히 발현되지 못함을 보여준다. 본 LSTM 구조의 한계와 향후 개선 방향에 대한 논의는 5절에서 다룬다.

<표 2> 변동성 예측 성능 (RMSE, Spearman, Hit Rate). ANN을 제외한 모형은 각 월의 마지막 거래일 예측 값을 사용. 굵은 글씨는 지표·기간 별 최고 성능. 각 셀의 별표 및 d_z 는 Ensemble 모형 대비 SBB 페어 검정이며, 양수 d_z 는 Ensemble 우위 방향이다.

Metric	Period	Ens.	LSTM	HAR	ANN
RMSE ↓	All	0.3520	0.3907 * ($d_z=+0.23$)	0.3603 ($d_z=+0.18$)	0.4181 ** ($d_z=+0.36$)
	R1 (회복)	0.3347	0.3757 *** ($d_z=+0.82$)	0.3313 ($d_z=-0.05$)	0.4746 * ($d_z=+0.48$)
	R2 (확장)	0.3603	0.3834 *** ($d_z=+1.03$)	0.3642 * ($d_z=+0.23$)	0.3930 *** ($d_z=+0.53$)
	R3 (위기)	0.3449	0.4302 ($d_z=+0.31$)	0.3732 ($d_z=+0.34$)	0.4480 * ($d_z=+0.44$)
	R4 (정상화)	0.3543	0.3719 *** ($d_z=+1.08$)	0.3595 * ($d_z=+0.44$)	0.3944 *** ($d_z=+0.75$)
Spearman ↑	All	0.6860	0.6490 *** ($d_z=+0.92$)	0.6795 * ($d_z=+0.25$)	0.6419 *** ($d_z=+0.69$)
	R1 (회복)	0.7735	0.7516 *** ($d_z=+1.12$)	0.7584 *** ($d_z=+0.86$)	0.7302 *** ($d_z=+0.75$)
	R2 (확장)	0.6512	0.6188 *** ($d_z=+1.88$)	0.6464 ($d_z=+0.21$)	0.6134 *** ($d_z=+0.79$)
	R3 (위기)	0.7071	0.6497 ** ($d_z=+0.78$)	0.7038 ($d_z=+0.09$)	0.6424 ** ($d_z=+0.66$)
	R4 (정상화)	0.6733	0.6352 *** ($d_z=+1.32$)	0.6657 * ($d_z=+0.41$)	0.6379 *** ($d_z=+0.82$)
Hit-Low (30%) ↑	All	0.6319	0.6128 *** ($d_z=+0.66$)	0.6241 ** ($d_z=+0.30$)	0.6023 *** ($d_z=+0.58$)
	R1 (회복)	0.7192	0.7086 * ($d_z=+0.44$)	0.7031 *** ($d_z=+0.74$)	0.6932 *** ($d_z=+0.61$)
	R2 (확장)	0.6070	0.5921 *** ($d_z=+0.62$)	0.6028 ($d_z=+0.18$)	0.5827 *** ($d_z=+0.58$)
	R3 (위기)	0.6309	0.5966 *** ($d_z=+0.88$)	0.6236 ($d_z=+0.21$)	0.5836 ** ($d_z=+0.66$)
	R4 (정상화)	0.6202	0.6012 *** ($d_z=+0.79$)	0.6093 * ($d_z=+0.47$)	0.5967 *** ($d_z=+0.52$)
Hit-High (30%) ↑	All	0.6612	0.6349 *** ($d_z=+0.87$)	0.6598 ($d_z=+0.06$)	0.6390 *** ($d_z=+0.49$)
	R1 (회복)	0.6986	0.6789 *** ($d_z=+1.03$)	0.6907 ** ($d_z=+0.45$)	0.6663 ** ($d_z=+0.62$)
	R2 (확장)	0.6376	0.6152 *** ($d_z=+1.10$)	0.6367 ($d_z=+0.05$)	0.6248 ** ($d_z=+0.34$)
	R3 (위기)	0.6895	0.6515 ** ($d_z=+0.75$)	0.6910 ($d_z=-0.05$)	0.6525 ** ($d_z=+0.63$)
	R4 (정상화)	0.6546	0.6267 *** ($d_z=+1.42$)	0.6543 ($d_z=+0.02$)	0.6353 *** ($d_z=+0.68$)

이러한 단독 모형 비교 결과에도 불구하고, 두 모형의 결합은 예측 오차의 분산 감소 측면에서 여전히 의미를 가진다. HAR 모형이 평균적으로 안정적이라 하더라도 두 모형은 서로 다른 함수 형

태(HAR: 변동성 성분의 선형 결합 / LSTM: 비선형 결합)로 변동성을 예측하므로 두 모형의 오차 시계열이 시점별로 상이한 양상을 보이며, 이는 결합 시 결합 오차의 분산 감소 효과를 기대할 수 있는 논리적 배경이 된다. 실제로 본 연구가 채택한 성능 가중 결합 방식으로 구성된 앙상블 모형은 분석 대상인 총 20개의 셀(4개 평가지표 × 5개 분석 기간) 중 18개에서 가장 우수한 성능을 보였으며, 나머지 2개 셀에서도 HAR 모형과 통계적으로 동등한 수준($|d_z| < 0.1$, 비유의)을 기록함으로써 두 단독 모형의 성과를 일관되게 상회한다. 이는 서로 다른 가정과 구조에 기반한 모형 결합이 단일 모형 대비 안정적인 예측력을 제공한다는 이론적 기대(2.2.3)와 궤를 같이 한다.

앙상블 모형과 ANN 기준 모형 간의 성과 격차는 모든 국면과 평가지표에서 통계적으로 유의하게 나타났으며, 특히 종목 간 서열 보존과 극단 변동성 식별 능력 측면에서 일관된 우위가 확인된다. 전체 기간 기준 Spearman 순위상관에서 앙상블 모형(0.6860)은 ANN 기준 모형(0.6419) 대비 0.044의 우위($p < .001$, $d_z = +0.69$)를, 하위 30% Hit Rate에서 0.030의 우위(0.6319 vs 0.6023, $p < .001$, $d_z = +0.58$)를, 상위 30% Hit Rate에서 0.022의 우위(0.6612 vs 0.6390, $p < .001$, $d_z = +0.49$)를 보였으며, 이러한 우위는 4개 국면 전반에서 일관되게 관찰된다. 본 연구의 자산 배분 전략은 저변동성 종목의 비중 확대와 고변동성 종목의 비중 축소를 동시에 수반한다는 점을 고려할 때, 이처럼 양 극단 영역에서 확보된 높은 식별 정확도는 예측 단계의 우수성이 포트폴리오의 실질적인 위험 조정수익률 제고로 전이될 수 있음을 지지하는 근거가 된다. 이러한 변동성 예측 성과가 실제 포트폴리오 구축 단계에서 어떻게 구현되는지는 이어지는 4.2절에서 상세히 논한다.

4.2. 기준 슬롯과 1차원 변형

본 절 이후 슬롯 조합은 $\langle \text{prior} \rangle _ \langle \text{p} \rangle _ \langle \text{q} \rangle _ \langle \text{omega} \rangle$ 순서의 토큰 결합으로 표기하며 (예: $\text{mcap_mcap_ff3_err} = (\mathbf{w}^{\text{mcap}}, \mathbf{p}^{\text{mcap}}, q^{\text{ff3}}, \omega^{\text{err}})$), 이는 Pyo and Lee (2018)의 기준 모형 설정에 해당한다. 본 절에서는 해당 기준 슬롯 조합을 출발점으로 설정하고, 네 차원의 입력 변수를 순차적으로 변경하며 앙상블 모형과 ANN 모형 간의 샤프 비율 차이를 비교·분석한다. 각 SET의 첫 행(★ 표시)은 기준 슬롯 조합을 의미하며, 해당 SET 내 변수 변경에 따른 성과 비교를 위해 반복하여 표기하였다.

또한 본 절과 4.4절 및 부록 B의 샤프 비율 차이 검정은 Ledoit & Wolf (2008) 방법을 따른다. 4.1절과 동일하게 Politis & Romano (1994)의 SBB를 페어 적용하며 ($B = 10,000$, 평균 블록 길이는 $T^{\frac{1}{3}}$ 규칙에 따라 기간별로 가변 적용: 30개월 → 3, 192개월 → 5), 두 샤프 비율 차이는 비교 대상 두 수익률의 월별 초과수익률과 그 제공 시계열로 구성된 4차원 벡터의 뉴이-웨스트 바틀렛 커널(Newey-West Bartlett kernel, Newey & West, 1987) HAC 공분산 ($\text{lag} = T^{\frac{1}{3}}$)과 델타 메소드로 표준화한다. 이

는 샤프 비율이 평균과 표준편차의 비율로 산출되어 표준오차 도출에 두 통계량의 결합 분포가 필요한 점, 그리고 금융 시계열의 비정규성(heavy tails) 및 변동성 군집(volatility clustering)을 통제하기 위함이다. HAC를 정규 점근 z-검정에 직접 적용하면 유한 표본에서 과대기각 문제가 발생하나, 본 연구는 HAC를 표준화(studentization)에만 사용하고 검정의 임계치는 부트스트랩 t -분포에서 산출하므로 이 문제를 우회한다. 검정은 부트스트랩 t -분포로부터 p -value와 95% 신뢰구간을 함께 산출하되, 본문에서는 해석에 필요한 경계 셀에 한해 신뢰구간을 인용하고 그 외에는 별표로 요약한다.

<표 3> Pyo and Lee (2018)의 기준 슬롯(mcap_mcap_ff3_err, ★)에서 한 차원씩 변경한 슬롯의 샤프 비율. 앙상블(E), ANN(A), 차이 $\Delta = E - A$. 녹색은 앙상블 우위, 적색은 ANN 우위. 별표(*)는 부트스트랩 검정 결과 $p < .05$.

차원	슬롯	All			R1			R2			R3			R4		
		E	A	Δ	E	A	Δ	E	A	Δ	E	A	Δ	E	A	Δ
SET 1 (q)	q^{lam}	0.913	0.952	-0.038	0.821	1.041	-0.220	0.953	1.213	-0.260	0.991	0.638	+0.353	0.864	0.833	+0.030
	q^{raw}	0.976	0.988	-0.012	0.818	1.044	-0.226	1.115	1.332	-0.217	0.999	0.643	+0.357	0.864	0.833	+0.030
	q^{inv}	0.995	0.982	+0.014	1.061	1.244	-0.183	1.100	1.084	+0.016	0.894	0.738	+0.156	0.915	0.963	-0.048
	q^{vsp}	0.949	0.948	+0.000	0.894	1.105	-0.211	1.030	1.067	-0.037	0.943	0.720	+0.223	0.891	0.958	-0.067
SET 2 (p)	$q^{ff3} \star$	0.946	0.945	+0.000	0.738	1.059	-0.321	1.287	1.076	+0.212	0.702	0.850	-0.148	0.940	0.712	+0.228
	$p^{mcap} \star$	0.946	0.945	+0.000	0.738	1.059	-0.321	1.287	1.076	+0.212	0.702	0.850	-0.148	0.940	0.712	+0.228
	p^{eq}	1.099	1.049	+0.050	0.872	1.024	-0.152	1.421	1.408	+0.013	0.888	0.705	+0.183	1.066	0.868	+0.198
SET 3 (w_{mkt})	p^{pp}	1.054	0.970	+0.084	0.806	0.809	-0.003	1.344	1.311	+0.033	0.870	0.714	+0.155	1.102	0.900	+0.202
	$w^{mcap} \star$	0.946	0.945	+0.000	0.738	1.059	-0.321	1.287	1.076	+0.212	0.702	0.850	-0.148	0.940	0.712	+0.228
	w^{eq}	0.894	0.889	+0.006	0.919	1.182	-0.262	1.276	1.007	+0.269	0.673	0.862	-0.189	0.623	0.420	+0.202
SET 4 (ω)	w^{pp}	0.918	0.904	+0.014	1.032	1.299	-0.267 *	1.298	1.038	+0.260	0.638	0.829	-0.191	0.651	0.394	+0.257
	$\omega^{err} \star$	0.946	0.945	+0.000	0.738	1.059	-0.321	1.287	1.076	+0.212	0.702	0.850	-0.148	0.940	0.712	+0.228
	ω^{bc}	0.830	0.871	-0.041	0.882	1.133	-0.251	1.178	1.043	+0.135	0.580	0.680	-0.100	0.599	0.637	-0.038

전체 분석 기간의 결과를 보면, 앙상블 모형은 다수 슬롯 조합에서 ANN 대비 우위를 점하고 있으나, 정작 기준 슬롯 자체에서의 샤프 비율 격차는 $\Delta = +0.0003$ 으로 사실상 0에 근접하며, 검정 결과 역시 $p = 0.998$, 95% 신뢰구간 $[-0.20, +0.19]$ 로 통계적으로 유의하다 할 수 없다. 이러한 결과는 앞선 변동성 예측 모형 자체의 우위가 실제 포트폴리오 성과로 직결되기 위해서는 BL을 구성하는 슬롯 차원의 설계가 함께 동반되어야 함을 시사한다. 이에 아래에서는 4개 차원별 변형에 따른 모형 간 성과 차이의 패턴을 분리하여 상세히 분석한다.

먼저 표 3의 q 변형 결과를 보면, 기준 슬롯의 q^{ff3} 는 FF3 회귀 기반으로 산출되어 부호 제약이 없는 반면, 본 연구가 추가한 네 가지 슬롯($q^{lam}, q^{raw}, q^{inv}, q^{vsp}$)은 구조적으로 $q \geq 0$ 이 항상 보장된다. R3 국면에서 $q \geq 0$ 슬롯은 앙상블 모형의 우위가 $\Delta = +0.156 \sim +0.357$ 로 방향의 일관성을 보이는 반면, q^{ff3} 는 격차의 방향이 ANN 우위로 반전된다($\Delta = -0.148$). 다만 표 3의 기준 슬롯 계열(p^{mcap} 조건)에 대한 검정에서는 어느 슬롯도 통계적 유의수준($p < .05$)에는 도달하지 않는다. 이는 위기 국면에서의 격차 방향은 q 부호의 안정성에 의존함을 시사하나, 표 3의 기준 슬롯 조건 하에서는 통계적 유의성까지는 나아가지 못함을 의미한다. 부호 안정성과 통계적 유의성의 관계에 대한 원인 해석과 슬롯별 검정 결과는 후술할 p 차원 분석 및 4.3절에서 상세히 다룬다.

$\mathbf{p}$ 를 기준 슬롯 $\mathbf{p}^{\text{mcap}}$ 에서 $\mathbf{p}^{\text{eq}}$ 또는 $\mathbf{p}^{\text{rp}}$ 로 변경하는 경우, 전체 기간의 샤프 비율은 앙상블 모형의 경우 0.946에서 각각 1.099, 1.054로 상승하고, ANN 모형 역시 0.945에서 1.049, 0.970으로 양 모형 모두 개선되는 양상을 보인다. 두 모형 간 격차 Δ 도 $\mathbf{p}^{\text{mcap}}$ 의 +0.000에서 $\mathbf{p}^{\text{eq}}$ +0.050, $\mathbf{p}^{\text{rp}}$ +0.084로 확대되나, 표 3의 단일 슬롯 수준에서는 세 슬롯 모두 통계적 유의수준에 도달하지 않는다. $\mathbf{p}$ 는 개별 종목의 변동성 예측 값을 포트폴리오 뷰로 종합하는 가중치를 결정하는데, $\mathbf{p}^{\text{mcap}}$ 는 시가총액 가중 방식으로 대형주에 비중이 집중되어 앙상블 모형이 식별한 개별 종목 순위 정보가 포트폴리오 가중치로 충분히 반영되지 못한다. 반면 $\mathbf{p}^{\text{eq}}$ 및 $\mathbf{p}^{\text{rp}}$ 는 대형주 집중을 완화하여 순위 정보의 반영 효율을 높이는 방향으로 작동한다. 다만 $\mathbf{p}$ 변형만으로는 표 3에서 확인한 바와 같이 통계적 확립에 도달하지 않으며, 앞서 q 차원에서 관찰한 부호 안정성($q \geq 0$)과 $\mathbf{p}$ 차원의 대형주 완화($\mathbf{p}^{\text{eq}}$, $\mathbf{p}^{\text{rp}}$)가 결합될 때 비로소 위기 국면 앙상블 우위가 통계적으로 확립된다. 4.3절 부록 B의 슬롯별 검증에서 R3 국면 45 슬롯 중 유의($p < .05$) 셀 16개가 모두 $q \geq 0$ 계열($q^{\text{lam}}, q^{\text{raw}}, q^{\text{inv}}, q^{\text{vsp}}$)과 $\mathbf{p}^{\text{eq}}$ 또는 $\mathbf{p}^{\text{rp}}$ 조합에 집중되는 반면, $q \geq 0$ 이더라도 $\mathbf{p}^{\text{mcap}}$ 조건 슬롯에서는 R3 유의 셀이 관찰되지 않는다는 대조가 이를 뒷받침한다. 이는 두 모형 간 포트폴리오 성과 차이의 통계적 유의성이 모형 예측력만으로는 확립되지 않으며, 슬롯 구조(q 부호 안정성 + $\mathbf{p}$ 대형주 완화)의 결합이 병행될 때 확립됨을 시사한다.

반면, 사전 분포 $\mathbf{w}_{\text{mkt}}$ 를 기준 슬롯 $\mathbf{w}^{\text{mcap}}$ 에서 $\mathbf{w}^{\text{eq}}$, $\mathbf{w}^{\text{rp}}$ 로 변경하더라도 Δ 의 부호 패턴은 기준 슬롯과 동일하게 유지된다. R1 국면에서는 ANN 우위 방향성이 세 슬롯 모두에서 관찰되며($\Delta = -0.321, -0.262, -0.267$), 이 중 $\mathbf{w}^{\text{rp}}$ 슬롯 한 개에서만 통계적 유의수준에 도달한다($p < .05$). $\mathbf{w}^{\text{mcap}}$ 은 신뢰구간 상한이 0에 근접하나 ($[-0.79, -0.08]$) 유의수준에는 도달하지 않는다($p = 0.062$). R3 국면에서는 세 슬롯 모두 ANN 우위($\Delta = -0.191 \sim -0.148$)이나 비유의 수준이며, R2와 R4 국면에서는 세 슬롯 모두 앙상블 우위 방향($\Delta = +0.202 \sim +0.269$)을 보이나 역시 비유의이다. 이러한 부호 패턴은 $\mathbf{w}_{\text{mkt}}$ 변경과 무관하게 보존되며 격차의 크기만 조정된다. 이는 사전 분포 차원이 모형 간 성과 차이의 방향성을 결정하기보다는 격차의 크기에만 영향을 미치는 차원으로 해석된다.

마지막으로 뷰 신뢰도(ω) 차원에서, 기준 슬롯 ω^{err} 에서 ω^{he} 로 변경할 경우 양 모형 모두 샤프 비율이 하락한다(앙상블: 0.946 $\rightarrow$ 0.830, ANN: 0.945 $\rightarrow$ 0.871). 이는 ω^{err} 은 전월 예측 오차를 기반으로 예측이 크게 빗나간 직후 포트폴리오 뷰의 신뢰도를 자동으로 낮추어 손실을 통제하는 기능을 수행하기 때문에, ω^{err} 선택이 양 모형의 자산 배분 안정성에 유리한 방향임을 보여준다(R1 회복 국면 제외). 반면 앙상블과 ANN 모형 간 페어 부트스트랩 검증에서는 ω 방식과 무관하게 어느 국면에서도 통계적 유의수준에 도달한 셀이 관찰되지 않는다. 즉 ω 차원은 개별 모형의 자산 배분 안정성에는 영향을 주나, 두 모형 간 격차에는 결정적이지 않은 차원으로 해석된다.

4.3. 슬롯 차원별 주변 분포


본 절에서는 4.2절에서 다룬 단일 차원 변경 결과가 전체 슬롯 조합에 대해서도 일관되게 나타나는지 검증한다. 이를 위해 각 슬롯 차원별로 나머지 세 차원의 모든 조합에 대해 평균을 산출한 주변 분포(Marginal Distribution)를 시각화 하여 제시한다. 전체 90개 슬롯 조합의 세부 성과는 부록 B에 수록하였다.

<표 4> p 변경에 따른 평균 샤프 비율 (q 5개 $\times$ w_{mkt} 3개 = 15 슬롯 평균, ω^{err} 고정). 앙상블(E), ANN(A), 차이 $\Delta = E - A$. 녹색은 앙상블 우위, 적색은 ANN 우위. 슬롯별 통계 검정 결과는 부록 표

A.7 참조.

	All			R1			R2			R3			R4		
p	E	A	Δ	E	A	Δ	E	A	Δ	E	A	Δ	E	A	Δ
p^{mcap}	0.929	0.948	-0.019	1.008	1.222	-0.214	1.104	1.157	-0.053	0.869	0.735	+0.134	0.633	0.614	+0.019
p^{eq}	1.038	0.970	+0.068	1.184	1.230	-0.046	1.303	1.314	-0.012	0.923	0.669	+0.253	0.492	0.415	+0.076
p^{ip}	1.008	0.920	+0.088	1.114	1.034	+0.081	1.248	1.238	+0.010	0.896	0.685	+0.212	0.555	0.479	+0.076

구간 $\times$ 차원별 주변 분포 — Sharpe



<그림 6> BL 슬롯 차원별 샤프 비율 주변 분포 (앙상블 vs ANN).

표 4는 $\omega = \omega^{\text{err}}$ 로 고정한 상태에서 $\mathbf{p}$ 가중치를 $\mathbf{p}^{\text{mcap}}, \mathbf{p}^{\text{eq}}, \mathbf{p}^{\text{rp}}$ 세 가지 방식으로 변경하고, 각 조합별로 5개의 q 와 3개의 $\mathbf{w}_{\text{mkt}}$ 조합(총 15개 슬롯)을 평균 낸 결과이다. 전체 분석 기간을 기준으로 앙상블 모형의 샤프 비율은 $\mathbf{p}^{\text{mcap}}$ 의 0.929에서 $\mathbf{p}^{\text{eq}}$ 1.038, $\mathbf{p}^{\text{rp}}$ 1.008으로 상승하며, ANN 모형 역시 $\mathbf{p}^{\text{mcap}}$ 0.948에서 $\mathbf{p}^{\text{eq}}$ 0.970으로 개선된다($\mathbf{p}^{\text{rp}}$ 는 0.920으로 소폭 감소). 두 모형 간 격차는 $\mathbf{p}^{\text{mcap}}$ 의 -0.019에서 $\mathbf{p}^{\text{eq}}$ +0.068, $\mathbf{p}^{\text{rp}}$ +0.088로, $\mathbf{p}$ 가중치를 대형주 집중 방식에서 균등·위험 기반으로 완화할수록 앙상블 우위 방향으로 이동하는 패턴이 확인된다(그림 6). 이는 앙상블 모형이 식별한 개별 종목 순위 정보가 대형주 비중 집중이 완화된 가중 방식에서 포트폴리오 가중치로 효과적으로 반영될 가능성을 시사한다. 다만, 이러한 방향성 이동은 관측치 수준의 패턴이며, 부록 표 A.7의 슬롯별 검정에서 전체 분석 기간(192개월) 45 슬롯 중 통계적 유의($p < .05$)에 도달하는 셀은 관찰되지 않는다. 관측치 방향성이 통계적 유의성으로 이어지는 양상은 국면별로 상이하게 나타나며, 이하 각 국면별로 분해하여 살펴본다.

R3(위기) 국면에서는 $\mathbf{p}$ 구성 방식과 무관하게 앙상블 모형이 일관된 우위를 보이며($\Delta = +0.134, +0.253, +0.212$), 표 5에서도 거의 모든 슬롯에서 앙상블 모형이 ANN 모형을 상회한다. 그러나 부록 표 A.7의 슬롯별 샤프 비율 검정 결과, 이러한 우위가 통계적으로 유의($p < .05$)한 셀은 R3 45 슬롯 중 16개(36%)에 국한되며, 이들은 앞선 4.2절에서 언급한 두 조건(q 부호 안정성 + $\mathbf{p}$ 대형주 완화)이 동시에 만족되는 슬롯에 집중된다. 즉, 앙상블 우위가 통계적으로 뒷받침되기 위해서는 두 조건의 결합이 수반되어야 하며, 이러한 R3 국면의 우위 패턴은 Sortino 비율과 MDD에서도 유사하게 관찰된다. 상세 슬롯별 성과 지표는 부록 B에 첨부하였다.

R1(회복)과 R2(확장) 국면에 대한 부록 표 A.7의 샤프 비율 검정 결과, R1에서는 45 슬롯 중 3개에서만 ANN 모형이 통계적으로 유의한 샤프 우위($p < .05$)를 보이며, R2에서는 유의한 슬롯이 없어 두 모형 간 통계적 차이가 관찰되지 않는다. 표 5의 단순 빈도분석에서도 R1·R2 두 국면 모두 $\mathbf{p}^{\text{mcap}}$ 과 $\mathbf{p}^{\text{eq}}$ 가중 방식에서 앙상블 모형의 샤프 비율이 ANN 모형을 하회하는 슬롯의 빈도가 더 높지만(R1: $\mathbf{p}^{\text{mcap}}$ 0/15, $\mathbf{p}^{\text{eq}}$ 1/15; R2: $\mathbf{p}^{\text{mcap}}, \mathbf{p}^{\text{eq}}$ 모두 5/15), 손실 규모 측면에서는 두 가중치 방식 간에 명확한 차이가 존재한다. R1 국면에서 $\mathbf{p}^{\text{mcap}}$ 의 평균 손실 $\Delta = -0.214$ 는 2011년 8월 미국 국가신용등급 강등 사태를 포함한 소수의 이례적 이벤트 발생 월에 손실이 집중된 결과이다. 이러한 충격은 대형주 비중 집중이 강한 $\mathbf{p}^{\text{mcap}}$ 구조 하에서 증폭되어 나타났다. 반면, $\mathbf{p}^{\text{eq}}$ 방식에서는 균등 배분 효과를 통해 특정 종목의 충격이 포트폴리오 전체로 전이되는 영향이 축소되어 평균 손실이 -0.046 수준으로 통제된다. 즉, $\mathbf{p}^{\text{eq}}$ 가중은 회복기 우위 빈도 면에서는 $\mathbf{p}^{\text{mcap}}$ 과 유사하나, $\mathbf{p}^{\text{mcap}}$ 의 대형주 비중 집중이 야기하는 대규모 손실 위험을 효과적으로 완화한다. 자세한 분석은 부록 C에서 확인할 수 있다.

<표 5> p 변경에 따른 앙상블 우위 슬롯 수 (15 슬롯 중 $\Delta > 0$ 인 슬롯, ω^{err} 고정).

p	All	R1	R2	R3	R4
p^{mcap}	5/15	0/15	5/15	12/15	7/15
p^{eq}	15/15	1/15	5/15	15/15	15/15
p^{rp}	15/15	14/15	9/15	15/15	15/15

그림 6의 q 차원을 보면, R3(위기) 국면에서 q^{lam} 과 q^{raw} 처럼 $q \geq 0$ 이 보장되어 저변동성 종목의 비중을 일관되게 확대하는 방식이 두 모형 간의 샤프 비율 차이를 가장 크게 만든다. 반면 부호 제약이 없는 q^{ff3} 의 주변 분포는 R3 국면에서 $\Delta = -0.014$ 를 기록하여 다른 네 가지 q 슬롯에서 관찰된 앙상블 모형의 우위가 사실상 소멸하며, 슬롯별 검정에서도 q^{ff3} 조건 9개 슬롯은 R3 국면에서 통계적으로 유의한 셀이 없다. 이는 앙상블 모형이 식별한 저변동성 종목의 순위 정보가 q 의 부호가 음수로 반전되지 않는 조건에서 포트폴리오 가중치로 보다 효과적으로 보존됨을 시사한다.

본 절에서 확인한 슬롯 구성이 단순 벤치마크 대비 실제로 의미 있는 성과를 갖는지는 4.4절에서 확인한다.

4.4. 벤치마크 성능 비교

본 절은 4.2–4.3절에서 확인한 변동성 예측 향상 및 슬롯 설계 효과가 표준 벤치마크 대비 실증 우위로 이어지는지 검증한다. 비교 대상은 세 외부 벤치마크(SPY, 1/ N 동일 가중, Risk Parity)와 Pyo and Lee (2018)의 ANN 앵커 슬롯(ANN-anchor: w^{mcap} , p^{mcap} , q^{ff3} , ω^{err}), 변동성 예측 모형만 앙상블로 교체한 앵커 슬롯(Ensemble-anchor), 그리고 본 연구의 두 옵션(Ensemble-defensive와 Ensemble-adaptive, 각 옵션마다 p^{eq} , p^{rp} 두 변형 — 총 4 슬롯)이다.

본 연구는 특정 단일 슬롯만을 최적 모형으로 권장하지 않으며, 운용 목표에 따라 선택 가능한 두 가지 옵션을 제안한다. 모든 시장 국면에서 저변동류를 일관되게 유지하는 방어형 옵션(Ensemble-defensive, q^{lam})과, q^{ff3} 의 크기와 부호가 시장 국면에 따라 변동하는 국면 적응형 옵션(Ensemble-adaptive, q^{ff3})이다. 각 옵션은 p^{eq} 또는 p^{rp} 두 변형으로 운용할 수 있으며, 두 변형은 후술하듯 거의 동등한 성과를 보인다.

표 6에서 네 가지 Ensemble 슬롯은 전체 분석 기간(All) 기준 모두 외부 벤치마크와 BL 앵커 슬롯의 성과를 상회한다. 전체 분석 기간의 샤프 비율은 Ensemble-defensive가 p^{eq} 1.07, p^{rp} 1.04를 기록하였고, Ensemble-adaptive가 p^{eq} 1.10, p^{rp} 1.05를 나타냈다. 이는 p 변형 선택과 무관하게 전통적 벤치마크인 SPY(0.93), 1/ N 동일 가중(0.86), Risk Parity(0.89), ANN-anchor(0.95), Ensemble-anchor(0.95) 성과를 모두 능가하는 수치이다. MDD 측면에서도 외부 벤치마크 및 ANN-anchor 대비 얇은 손실을 기록하며, 특히 Ensemble-defensive 두 변형의 방어력이 가장 우수하다. 이와 관련한 상세 수치는 부록 E에 수록하였다.


<표 6> 벤치마크 성능 비교 — 샤프 비율 $\times$ 5 기간. Ensemble 슬롯은 모두 $\mathbf{w}_{mkt} = \mathbf{w}^{mcap}$ 고정, $\mathbf{p}^{eq}$ 와 $\mathbf{p}^{rp}$ 두 변형을 비교한다. 위첨자는 각 유의 셀($p < .05$)의 샤프 검정 상대를 표시한다. ^a SPY, ^b 1/N, ^c Risk Parity. ANN-anchor 및 Ensemble-anchor 대비 검정에서는 유의 셀이 없다. 보조지표 (MDD, Sortino)는 부록 E 참조.

Strategy	All	R1	R2	R3	R4
SPY (market)	0.93	0.81	1.23	0.61	1.19
1/N (equal-weight)	0.86	0.78	1.23	0.70	0.47
Risk Parity (1/ σ)	0.89	0.91	1.28	0.67	0.45
ANN-anchor (Pyo & Lee, 2018)	0.95	1.06	1.08	0.85	0.71
Ensemble-anchor (σ 모형 교체)	0.95	0.74	1.29	0.70	0.94
Ensemble-defensive ($\mathbf{p}^{eq}, \mathbf{q}^{lam}$)	1.07	1.08	1.32	0.96	0.64
Ensemble-defensive ($\mathbf{p}^{rp}, \mathbf{q}^{lam}$)	1.04	0.98	1.28	0.95	0.71
Ensemble-adaptive ($\mathbf{p}^{eq}, \mathbf{q}^{ff3}$)	1.10	0.87	1.42	0.89 ^a	1.07 ^{bc}
Ensemble-adaptive ($\mathbf{p}^{rp}, \mathbf{q}^{ff3}$)	1.05	0.81	1.34	0.87	1.10^{bc}

이러한 관측치 우위가 통계적으로 확립되는지 검증하기 위해, 4 Ensemble 옵션 슬롯과 5가지 비교 대상(SPY, 1/N, Risk Parity, ANN-anchor, Ensemble-anchor)에 대해 전체 기간 및 4가지 국면에 대해 각각 검정을 수행하였다(총 100 검정). 그 결과, 전체 분석 기간(192개월)에 해당하는 20 검정에서 어느 옵션도 비교 대상 대비 통계적으로 유의($p < .05$)하지 않았으며, Ensemble-adaptive($\mathbf{p}^{eq}$)만 SPY 및 1/N 대비 유의 경계 수준(각 $p = 0.080, p = 0.070$)의 결과를 보인다. 국면별 80 검정에서는 5셀의 유의성이 관찰되며, 모두 Ensemble-adaptive에 집중된다. 다만 100 검정 중 5셀(5%)이라는 발생 빈도는 유의수준 $\alpha = 0.05$ 하에서 우연 발생 기대치와 일치하는 수준으로 다중 검정 관점에서는 신중한 해석이 요구된다. 특히 R4 강세장의 4개 유의 셀은 1/N과 Risk Parity가 해당 국면에서 저조한 성과(각 0.47, 0.45)를 보이며 격차가 커진 결과에 가깝다. 한편 σ 모형만 앙상블로 교체한 Ensemble-anchor를 기준으로 네 옵션 슬롯이 통계적으로 개선을 보이는지 검정한 결과에서도 20 검정 모두 유의수준에 도달하지 못하였다.

통계 검정 결과와는 별개로, 두 가지 Ensemble 옵션은 시장 국면에 따라 보완적인 특성을 보인다. Ensemble-defensive는 R1(회복) 국면과 R3(위기) 국면 등 시장 변동성이 상승하는 국면에서 강점을 보인다($\mathbf{p}^{eq}$ 기준 샤프 비율 각각 1.08, 0.96). 이는 $\mathbf{q}^{lam}$ 의 양수 제약이 모든 시점에서 저변동류를 일관되게 유지하기 때문이다. 반면 Ensemble-adaptive는 R2(확장) 국면과 R4(정상화) 강세장 국면에서 강점을 보인다($\mathbf{p}^{eq}$ 기준 샤프 비율 각각 1.42, 1.07). 이는 $\mathbf{q}^{ff3}$ 의 FF3 회귀 기반 구조가 강세장에서류를 적응적으로 재조정함으로써 상승장 포착 능력을 제공하기 때문이다. R3(위기) 국면에서는 두 옵션의 네 가지 변형 슬롯이 모두 ANN-anchor(0.85)를 상회하였으며(0.87 ~ 0.96), R4 강세장 국면에서는 Ensemble-adaptive의 두 변형 슬롯이 ANN-anchor(0.71)를 크게 상회하는 성과(1.07, 1.10)를 기록했다. 한편 $\mathbf{p}$ 가중 방식의 효과는 시장 국면에 따라 비대칭적으로 작동하는 특성을 보였다. R1 국면에서는 $\mathbf{p}^{eq}$ 방식이 $\mathbf{p}^{rp}$ 방식 대비 Ensemble-defensive에서 약 0.10, Ensemble-adaptive에서 약 0.06의 성과 우위를 나타냈다. 반대로 R4 국면에서는 $\mathbf{p}^{rp}$ 방식이 두 옵션 모두에

서 p^{eq} 방식을 약간 상회하는 결과(Ensemble-defensive 0.71 vs 0.64, Ensemble-adaptive 1.10 vs 1.07)를 보였다.



<그림 7> 누적수익률(상단, log scale) 및 drawdown(하단), 2010-01 ~ 2025-12. R3(위기) 국면 음영.

파랑=Ensemble-defensive, 초록=Ensemble-adaptive.

Ensemble-defensive와 Ensemble-adaptive는 전체 분석 기간 샤프 비율과 누적 수익률이 거의 동등하지만(그림 7), 국면별 성과 구성이 상이하므로 운용 목표에 따라 선택할 수 있다. 저변동 정체성을 모든 시장 국면에서 엄격히 유지하려는 보수적 운용 방식에는 Ensemble-defensive가, 강세장에서의 추가 상승 수익을 일정 부분 허용하는 적응적 운용 방식에는 Ensemble-adaptive가 적합하다. 두 가지 옵션 모두 표준 벤치마크 대비 관측치 기준 일관된 성과 우위를 제공하며, p^{eq} 와 p^{rp} 어느 가중 방식을 적용하더라도 일관된 성과를 보여 p 변형 선택에 강건하다.

다만 본 절의 벤치마크 대비 관측치 우위($\Delta \approx 0.10 \sim 0.24$)는 실무적으로 의미 있는 크기이나, 대부분의 검정 셀에서 신뢰구간이 0을 포함하며 통계적 유의수준에 도달하지 못하였다. 이는 4.2절에서 도입한 HAC 표준오차가 금융 시계열의 비정규성과 변동성 군집을 반영하여 관측 격차와 유사한 크기($SE \approx 0.09 \sim 0.18$)로 산출되며, 그 결과 대부분의 셀에서 t-값이 유의수준을 넘지 못하기 때문이다. 국면별 표본(30 ~ 42개월)의 짧은 길이도 검정력을 추가로 제한한다. 이러한 샤프 비율 차이 검정의 본질적 특성과 향후 관측 기간 확장을 통한 재검증 방향은 5절에서 논의한다. q^{ff3}

가 강세장에서 뷰를 적응적으로 재조정하는 구체적 메커니즘 및 $\mathbf{p}$ 가중치의 완화 효과는 부록 D에서 상세히 분석한다.

5. 결론 및 한계

본 연구는 Pyo and Lee (2018)의 KOSPI 200 BL 저변동 프레임워크를 S&P 500 시장에 적용하면서, 변동성 예측 모형과 BL 슬롯 구성을 재검토하고 2010–2025년 192개월을 4개 시장 국면(R1 회복, R2 확장, R3 위기, R4 정상화)으로 분해하여 평가하였다. 단일 슬롯 비교에 그치지 않고 90개 슬롯을 차원별($\mathbf{p} \times \mathbf{w}_{mkt} \times q \times \omega$)로 분해하여 주변 분포를 산출하고, 이를 4개 국면으로 재분해하는 프레임워크를 통해 운용 목표에 따른 슬롯 선택 근거를 제시한 점이 본 연구의 분석적 기여이다.

LSTM-HAR 앙상블 모형은 ANN 모형 대비 변동성 예측 정확도(RMSE, Spearman, Hit Rate)에서 전국면 일관된 우위를 보였으며, 특히 R3(위기) 국면에서 격차가 전체 분석 기간 대비 약 1.5-1.7배 확대되었다. R3 국면은 COVID-19 팬데믹 충격(2020년 1-2분기)과 2022년 긴축 약세장이 복합된 시기로, 시장 전반의 변동성 수준과 종목 간 변동성 격차가 모두 극대화된 환경이었다. 이러한 국면에서는 종목별 변동성 순위가 빠르게 재편되며, 이를 안정적으로 식별하는 능력이 포트폴리오 성과에 가장 결정적으로 작용한 것으로 해석된다. 다만 이러한 예측 우위가 포트폴리오 성과로 전이되기 위해서는 슬롯 설계, 특히 $\mathbf{p}$ 의 대형주 비중 집중 완화가 동반되어야 한다. 변동성 예측 모형만 앙상블로 교체한 Ensemble-anchor는 ANN-anchor와 샤프 비율이 동률(0.95)에 머무르나, $\mathbf{p}$ 가중치를 $\mathbf{p}^{eq}$ 또는 $\mathbf{p}^{rp}$ 로 변경하면 두 슬롯 구성 모두 관측치 기준 +0.09 ~ +0.15의 샤프 비율 개선이 일관되게 나타난다.

본 연구는 자산배분 프로세스에서 단일한 최적 슬롯 설정을 고집하기보다, 운용 목표에 따라 BL의 입력 변수를 유연하게 다원화할 수 있는 실무적 가이드라인을 제시하였다. 모든 시장 국면에서 저변동 정체성을 엄격히 유지하려는 보수적 운용에는 q^{lam} 기반의 Ensemble-defensive가, 강세장 국면에서 시장 랠리를 추종하여 초과 수익을 추구하는 동적 자산 배분에는 q^{ff3} 기반의 Ensemble-adaptive가 유용한 대안이 될 수 있음을 확인하였다. 두 전략 모두 $\mathbf{p}^{eq}$ 와 $\mathbf{p}^{rp}$ 중 어느 변형을 선택하더라도, 편측 20bp의 거래비용을 차감 후 전통적 벤치마크 및 ANN-anchor 대비 전체 분석 기간(All) 기준으로 관측치 수준의 성과 우위를 보였다. 이는 변동성 예측 모형의 고도화가 단일한 최적 슬롯 구조에 국한되지 않고, 운용 목표에 맞는 유연한 BL 입력 설계와 결합될 때 실질적인 위험 조정수익률 제고로 이어질 가능성을 시사한다.

다만 이러한 관측치 수준의 우위가 통계적으로 확립되는 조건은 매우 제한적이다. 슬롯별 검정 및 벤치마크 대비 검정 모두 대부분의 셀에서 유의수준($p < .05$)에 도달하지 못하며, 통계적 확립은

R3(위기) 국면에서 q 부호 안정성($q \geq 0$)과 p 대형주 완화가 결합된 슬롯 조합에 국한된다. 이 R3 조건은 특정 시점의 우연적 결과라기보다 저변동 류의 안정적 반영이라는 메커니즘으로 도출되므로, 다른 시장 및 다른 기간의 위기 국면에서도 유사 조건 하에서 재현될 가능성을 보인다. 다만 본 연구 표본은 미국 대형주 및 2010-2025년(192개월)에 국한되며, 특히 대형주 편중 완화는 S&P 500의 시가총액 상위 집중 구조에서 두드러진 것으로, 이러한 구조가 완화된 시장에서는 효과가 축소될 수 있어 시장별 재분석을 통한 후속 연구가 필요하다.

아울러 본 연구에서 검증된 LSTM-HAR 앙상블 변동성 예측 결과는 본문에서 제안한 BL 포트폴리오 전략뿐만 아니라 다양한 재무적 의사결정 분야로 확장될 수 있다. 우선, 예측된 변동성 시계열은 금융기관의 리스크 관리 시스템에서 Value-at-Risk(VaR) 및 조건부 기대손실(Expected Shortfall) 산출의 핵심 입력값으로 활용되어 하방 위험 통제력을 높이는 데 기여할 수 있다. 다음으로, 옵션 가격 결정에서 기초자산의 변동성은 유일하게 관측 불가능한 파라미터이므로, 본 연구의 예측 변동성을 옵션 시장의 내재변동성과 비교하여 정교한 델타-베가 헤징(Delta-Vega Hedging) 전략의 기초 자료로 활용할 수 있다. 마지막으로, 시스템 트레이딩 및 퀀트 펀드의 변동성 스케일링(Volatility Scaling) 기법에 도입하여, 예측된 변동성이 높은 국면에서는 선제적으로 레버리지를 축소하는 등 시장 국면에 적응적인 리스크 통제 규칙을 설계할 수 있다. 다만 본 연구가 사용한 LSTM 모형은 4채널($RV_{d/w/m}$, $\log(VIX)$)의 입력 피처와 단일 은닉층으로 구성된 단순한 구조이므로, 위 응용 분야로의 확장을 위해서는 거시 경제 변수, 뉴스 감성 정보, 옵션 시장 정보 등의 추가 신호 도입과 다층(Multi-layer) 및 어텐션(Attention) 구조로 고도화하여 예측 정확도를 추가적으로 개선할 필요가 있다.

본 연구는 다음과 같은 한계를 가진다. 첫째, 야후 파이낸스 데이터의 가용성 제약으로 인해 833개 종목 중 216개가 분석에서 누락되어 최종 617개 종목만을 대상으로 실증 분석을 수행하였다. 시점별 멤버십 필터링을 통해 생존 편향을 완화하였으나, 이러한 가용성 한계는 포트폴리오의 절대 성과를 과대 추정하는 방향과 위기 국면에 사라진 고변동 종목의 누락으로 인해 저변동성 우위 자체를 과소 추정하는 방향으로 동시에 작용할 수 있어, 편향의 방향을 단정하기 어렵다.

둘째, 본 연구의 통계 검정 결과는 검정력 제한을 포함한다. Ledoit & Wolf (2008)의 HAC studentized 부트스트랩 프레임에서 산출된 표준오차가 관측 격차와 유사한 크기($SE \approx 0.09 \sim 0.18$)로 나타나고, 국면 표본이 30~42개월로 짧아 대부분의 셀에서 검정 결과가 유의하지 않다. 이는 방법론적 결함이라기보다 금융 시계열의 실제 특성을 정직하게 반영한 결과로 해석된다. Ledoit & Wolf (2008)는 두꺼운 꼬리 혹은 시계열 특성을 갖는 소·중 표본에서 부트스트랩 임계값이 정규 임계값보다 커져 HAC 직접 검정 대비 보수적인 결과를 보이는 것을 논증하였다. 이들

의 실증 분석($T = 120$)에서도 관측된 뮤추얼 펀드 쌍(월별 샤프 비율 격차 0.097)과 헤지 펀드 쌍(월별 격차 0.447) 두 사례 모두에서 검정 결과가 $\alpha = 0.05$ 에서 귀무가설을 기각하지 못함을 보고하였다. 따라서, 본 연구에서 관측된 방향성과 통계적 유의성 간의 괴리는 특정한 데이터·모형의 한계가 아니라, 금융 시계열에서 studentized 부트스트랩 검정 방식의 검정력 특성임을 시사한다. 향후 관측 기간 확장 및 일별·시간별 고빈도 데이터를 활용한 재검증이 필요하다.

셋째, 본 연구에서 관찰된 국면별 성과 결과와 슬롯 메커니즘은 실증적 관찰에 머무르며 인과적 규명에 이르지 못한다. R1(회복) 국면에서 관측된 앙상블 모형 약세의 시점 집중성(부록 C절)과 강세장 국면에서 발생한 q^{ff3} 의 부호 반전 현상(부록 D절) 역시 직관적인 합리성을 넘어선 인과적 검증은 본 연구의 분석 범위를 벗어난다. 향후 연구에서는 예측 모형 고도화, 데이터 가용성의 추가 확보, 그리고 슬롯 간 인과적 분해를 통해 본 연구의 실증적 발견을 보완할 필요가 있다.

참고문헌

[국외 문헌]

Baker, M., Bradley, B., & Wurgler, J. (2011). Benchmarks as limits to arbitrage: Understanding the low-volatility anomaly. *Financial Analysts Journal*, 67(1), 40–54. <https://doi.org/10.2469/faj.v67.n1.4>

Barua, R., & Sharma, A. K. (2023). Using fear, greed and machine learning for optimizing global portfolios: A Black-Litterman approach. *Finance Research Letters*, 58, 104515. <https://doi.org/10.1016/j.frl.2023.104515>

Bates, J. M., & Granger, C. W. (1969). The combination of forecasts. *Journal of the Operational Research Society*, 20(4), 451–468. <https://doi.org/10.1057/jors.1969.103>

Black, F., & Litterman, R. (1992). Global portfolio optimization. *Financial Analysts Journal*, 48(5), 28–43. <https://doi.org/10.2469/faj.v48.n5.28>

Blitz, D., & van Vliet, P. (2007). The volatility effect: Lower risk without lower return. *The Journal of Portfolio Management*, 34(1), 102–113. <https://doi.org/10.3905/jpm.2007.698039>

Bucci, A. (2020). Realized volatility forecasting with neural networks. *Journal of Financial Econometrics*, 18(3), 502–531. <https://doi.org/10.1093/jjfinec/nbaa008>

Cochrane, J. H. (2005). *Asset Pricing* (Revised ed.). Princeton, NJ: Princeton University Press.

Cohen, J. (1988). *Statistical power analysis for the behavioral sciences* (2nd ed.). Lawrence Erlbaum Associates.

Cont, R. (2001). Empirical properties of asset returns: stylized facts and statistical issues. *Quantitative Finance*, 1(2), 223–236. <https://doi.org/10.1080/713665670>

- Corsi, F. (2009). A simple approximate long-memory model of realized volatility. *Journal of Financial Econometrics*, 7(2), 174–196. <https://doi.org/10.1093/jfinec/nbp001>
- DeMiguel, V., Garlappi, L., & Uppal, R. (2009). Optimal versus naive diversification: How inefficient is the 1/N portfolio strategy? *The Review of Financial Studies*, 22(5), 1915–1953. <https://doi.org/10.1093/rfs/hhm075>
- Diebold, F. X., & Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263. <https://doi.org/10.1080/07350015.1995.10524599>
- Fama, E. F., & French, K. R. (1993). Common risk factors in the returns on stocks and bonds. *Journal of Financial Economics*, 33(1), 3–56. [https://doi.org/10.1016/0304-405x\(93\)90023-5](https://doi.org/10.1016/0304-405x(93)90023-5)
- Fama, E. F., & French, K. R. (2015). A five-factor asset pricing model. *Journal of financial economics*, 116(1), 1–22. <https://doi.org/10.1016/j.jfineco.2014.10.010>
- Fama, E. F., & MacBeth, J. D. (1973). Risk, return, and equilibrium: Empirical tests. *Journal of Political Economy*, 81(3), 607–636. <https://doi.org/10.1086/260061>
- Frazzini, A., & Pedersen, L. H. (2014). Betting against beta. *Journal of Financial Economics*, 111(1), 1–25. <https://doi.org/10.1016/j.jfineco.2013.10.005>
- Gers, F. A., Schmidhuber, J., & Cummins, F. (2000). Learning to forget: Continual prediction with LSTM. *Neural Computation*, 12(10), 2451–2471. <https://doi.org/10.1162/089976600300015015>
- Hamilton, J. D. (1989). A new approach to the economic analysis of nonstationary time series and the business cycle. *Econometrica*, 57(2), 357–384. <https://doi.org/10.2307/1912559>
- He, G., & Litterman, R. (1999). The intuition behind Black-Litterman model portfolios. Goldman Sachs Investment Management Research. <https://ssrn.com/abstract=334304>
- Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735–1780. <https://doi.org/10.1162/neco.1997.9.8.1735>
- Kim, H. Y., & Won, C. H. (2018). Forecasting the volatility of stock price index: A hybrid model integrating LSTM with multiple GARCH-type models. *Expert Systems with Applications*, 103, 25–37. <https://doi.org/10.1016/j.eswa.2018.03.002>
- Ledoit, O., & Wolf, M. (2004). A well-conditioned estimator for large-dimensional covariance matrices. *Journal of Multivariate Analysis*, 88(2), 365–411. [https://doi.org/10.1016/s0047-259x\(03\)00096-4](https://doi.org/10.1016/s0047-259x(03)00096-4)
- Ledoit, O., & Wolf, M. (2008). Robust performance hypothesis testing with the Sharpe ratio. *Journal of Empirical Finance*, 15(5), 850–859. <https://doi.org/10.1016/j.jempfin.2008.03.002>
- Lee, Y., Kim, Y., Kim, J., Kim, S., & Lee, Y. (2025). LLM-Enhanced Black-Litterman Portfolio

Optimization. *arXiv Preprint arXiv:2504.14345*. <https://doi.org/10.48550/arXiv.2504.14345>

López de Prado, M. (2018). *Advances in Financial Machine Learning*. Hoboken, NJ: John Wiley & Sons.

Maillard, S., Roncalli, T., & Teïletche, J. (2010). The properties of equally weighted risk contribution portfolios. *The Journal of Portfolio Management*, 36(4), 60–70. <https://doi.org/10.3905/jpm.2010.36.4.060>

Markowitz, H. (1952). Portfolio selection. *The Journal of Finance*, 7(1), 77–91. <https://doi.org/10.1111/j.1540-6261.1952.tb01525.x>

Müller, U. A., Dacorogna, M. M., Davé, R. D., Olsen, R. B., Pictet, O. V., & von Weizsäcker, J. E. (1997). Volatilities of different time resolutions—Analyzing the dynamics of market components. *Journal of Empirical Finance*, 4(2–3), 213–239. [https://doi.org/10.1016/s0927-5398\(97\)00007-8](https://doi.org/10.1016/s0927-5398(97)00007-8)

Newey, W. K., & West, K. D. (1987). A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, 55(3), 703–708. <https://doi.org/10.2307/1913610>

Politis, D. N., & Romano, J. P. (1994). The stationary bootstrap. *Journal of the American Statistical Association*, 89(428), 1303–1313. <https://doi.org/10.1080/01621459.1994.10476870>

Pyo, S., & Lee, J. (2018). Exploiting the low-risk anomaly using machine learning to enhance the Black-Litterman framework. *Pacific-Basin Finance Journal*, 51, 1–12. <https://doi.org/10.1016/j.pacfin.2018.06.002>

Rumelhart, D. E., Hinton, G. E., & Williams, R. J. (1986). Learning representations by back-propagating errors. *Nature*, 323(6088), 533–536. <https://doi.org/10.1038/323533a0>

Sortino, F. A., & Price, L. N. (1994). Performance measurement in a downside risk framework. *The Journal of Investing*, 3(3), 59–64. <https://doi.org/10.3905/joi.3.3.59>

Su, X., Lu, K., & Yen, J. (2026). Objective Black-Litterman views through deep learning: A novel hybrid model for enhanced portfolio returns. *Expert Systems with Applications*, 295, 128868. <https://doi.org/10.1016/j.eswa.2025.128868>

Timmermann, A. (2006). Forecast Combinations. In G. Elliott, C. W. J. Granger, & A. Timmermann (Eds.), *Handbook of Economic Forecasting* (Vol. 1, pp. 135–196). Amsterdam, The Netherlands: Elsevier.

Whaley, R. E. (2009). Understanding the VIX. *The Journal of Portfolio Management*, 35(3), 98–105. <https://doi.org/10.3905/jpm.2009.35.3.098>

부록 A. HMM 기반 시장 국면 분류

Hidden Markov Model(HMM, Hamilton, 1989)은 관측 불가능한 잠재 상태인 시장 국면(Regime)이 확률적으로 전이하며 관측 데이터를 생성한다고 가정하는 통계 모형으로, 시장 국면처럼 직접 관측되지 않는 구조적 상태를 데이터를 기반으로 식별하는 데 적합하다. 본 연구는 HMM을 활용하여 분석 기간(2010-2025)의 시장 국면을 사후적으로 정의하고, 이를 포트폴리오 성과 분해의 기준으로 활용한다.

A.1 데이터 및 학습 기간

HMM 학습에는 Fama-French 5팩터(Fama-French 5-factor model, FF5, Fama & French, 2015)(일별), 매크로 지표 5개(VIX, 장단기 금리차 등), 그리고 개별 종목 일별 수익률로부터 산출한 동일 가중 시장 수익률을 결합한 데이터를 사용하였다. 학습 기간은 2004년 4월부터 2026년 2월까지이며, 유효 거래일은 총 5,512일이다.

HMM은 실시간 트레이딩 신호 생성이 아닌 사후적 시장 국면 정의가 목적이므로, 전체 구간 학습 방식의 미래 정보 반영 문제(look-ahead bias)는 본 연구의 분석 목적상 해당되지 않는다. 또한 국면 레이블은 BL 모형 학습 과정에 직접 투입되지 않으므로 정보 누설 경로도 없다.

A.2 입력 피처

16개 후보 피처 중 이론적 근거를 먼저 적용하고, ADF 단위근 검정·상관 행렬·분산팽창지수(VIF) 다중공선성 검증을 통해 최종 6개 피처를 선별하였다(표 A.1). 통계 검증은 전체 데이터를 기반으로 계산하였으며, 입력 데이터는 Z-score 방식으로 표준화 후 HMM에 투입하였다.

<표 A.1> HMM 입력 피처 선택 결과

피처	설명	선택 근거
mkt _{rf}	시장 초과수익률 (일별)	Bull/Bear 구분의 직접 수익 신호
vol _{21ddaily}	21일 실현변동성	국면 라벨링 기준 (변동성 순 정렬)
vol _{ratio}	단기/장기 변동성 비율	국면 전환 선행 신호 (>1이면 변동성 급증)
vix _{basis}	기대변동성 - 실현변동성	패닉 국면 식별 (음수 = 공포 실현, Bear/Crisis)
t10y2y _{chg}	장단기 금리차 1차 차분	경기 국면 변화 선행지표 (ADF 비정상으로 대체)
mom	모멘텀 팩터	추세 지속성 (Bull: 양수, Bear: 음수)

A.3 모형 설정 및 국면 수 선택

Gaussian HMM을 사용하였으며, 방출 분포는 국면별 독립적인 완전 공분산 행렬(full covariance) 구조로 설정하였다. $n = 3, 4, 5$ 에 대해 전체 기간 HMM을 각각 학습하고 국면 안정성과 경제적 해석 가능성을 기준으로 최적 국면 수를 비교하였다.

$n = 4$ 및 $n = 5$ 에서 추가로 분리되는 국면은 Bull이 Mild_Bull로 세분화되는 형태이나, 이 세분화가 GFC(글로벌 금융위기)·COVID·2022 Bear 등 기존 시장 사건과의 대응 관계에서 $n = 3$ 대비 명확한 우위를 보이지 않는다. Bear 및 위기 국면은 n 에 관계없이 일관되게 포착되므로, 경제적 해석 가능성과 국면 레이블 단순성을 기준으로 $n = 3$ 을 최종 채택하였다. 국면 레이블은 각 국면의 평균 vol_21d_daily 값 기준 오름차순으로 Bull(저변동·강세), Neutral(중변동·중립), Bear(고변동·약세) 순서로 부여하였다.

$n = 3, 4, 5$ 비교 결과, n 이 커질수록 평균 최대 사후 확률이 낮아지며($n = 3$: 0.984, $n = 4$: 0.971, $n = 5$: 0.976), 고확신 구간($\geq 90\%$) 비율도 감소한다. $n = 3$ 에서 전체 거래일의 94.5%가 고확신 구간에 해당해 국면 레이블 신뢰성이 가장 우수하였으며, 이를 최종 채택하였다.

<표 A.2> 국면 분류 모형 확신도

n	평균 최대 사후 확률	$\geq 90\%$ 고확신	70~90%	$< 70\%$ 불확실
3	0.984	94.5% (5,207일)	3.8% (207일)	1.8% (98일)
4	0.971	90.9% (5,012일)	5.5% (301일)	3.6% (199일)
5	0.976	92.2% (5,084일)	5.1% (279일)	2.7% (149일)

* 최대 사후 확률: 각 거래일에서 가장 높은 국면 소속 사후 확률.

A.4 국면별 기초 통계

$n = 3$ 기준 각 국면의 기초 통계는 표 A.3와 같다. Bear 국면의 일평균 변동성은 Bull 대비 약 3.5배 (2.271% / 0.653%), VIX는 약 2.5배(35.0 / 14.0)로 높다. 일평균 수익률·변동성·VIX 모두 Bull → Neutral → Bear 순서로 단조 증가/감소하여, 각 국면이 서로 다른 시장 체질을 나타냄을 확인하였다.

<표 A.3> 국면별 기초 통계 ($n = 3$)

국면	비중	거래일	일평균 수익률	일평균 변동성	평균 VIX
Bull	52.9%	2,914일	+0.063%	0.653%	14.0
Neutral	34.1%	1,877일	+0.025%	1.070%	20.7
Bear	13.1%	721일	-0.002%	2.271%	35.0

* 수익률 및 변동성은 일별 단위. VIX는 연환산 % (참고 수치).

A.5 전이 행렬

$n = 3$ 기준 일별 국면 전이 행렬은 표 A.4와 같다. 대각선(자기전이) 확률이 0.969 이상으로, 국면은 일별 노이즈가 아닌 수 주~수 달 단위로 지속되는 안정적 상태임을 확인하였다. Bull ↔ Bear 직접 전이 확률은 사실상 0으로, 국면 전환은 인접 상태를 경유해 점진적으로 이루어진다. 이러한 높은 국면 지속성은 국면 신호를 월별 리밸런싱 전략에 활용하기 위한 충분한 조건이 된다.

<표 A.4> 전이 행렬 ($n = 3$, 일별)

	→ Bull	→ Neutral	→ Bear
Bull	0.987	0.012	~0
Neutral	0.019	0.970	0.011
Bear	~0	0.031	0.969

A.6 구조적 전환점

비터비(Viterbi) 알고리즘으로 추출한 최적 국면 경로에서 이전 국면 ≥ 63 거래일(약 3개월), 새 국면 ≥ 63 거래일을 동시에 충족하는 경우만 구조적 전환점으로 정의하여 단기 노이즈를 제거하였다. 추출된 전환점은 표 A.5와 같으며, post-GFC 본격 강세(2012), COVID 직전 강세(2019), AI 랠리 시작(2023) 등 실제 시장 사건과 시기적으로 일치한다.

<표 A.5> 구조적 전환점 ($n = 3$ 기준, 양방향 ≥ 63 거래일 조건)

전환일	전환 방향	대응 시장 사건	비고
2012-08-15	Neutral → Bull	post-GFC 본격 강세	R1/R2 경계 근거
2019-11-05	Neutral → Bull	COVID 직전 강세	R2/R3 경계 근거
2023-06-05	Bear/Neutral → Bull	AI 랠리 시작	R3/R4 경계 근거
2024-08-01	Bull → Neutral	2024 금리 인하 기대 후퇴	분석 기간 내 마지막 전환점

$n = 3$ 기준 전환점(2023-06-05)을 분기말로 조정하여 R3와 R4의 경계를 2023년 6월 말로 설정하였다. 2024-08-01 전환점(Bull → Neutral)은 R4 내부의 국면 변화로, 평가 국면 경계 조정에는 반영하지 않았다.

A.7 평가 국면 정의

HMM 전환점을 분기말 기준으로 조정하고, COVID 시작 및 AI 랠리를 경제적 직관에 맞추어, 본 연구의 평가 구간을 표 A.6와 같이 4개 국면으로 정의하였다.

<표 A.6> 본 연구 평가 국면 정의

국면	기간	거래일	해석
R1	2010-01 ~ 2012-06 (30개월)	약 630일	GFC 회복·유럽 재정위기 국면
R2	2012-07 ~ 2019-12 (90개월)	약 1,890일	저변동 장기 확장 국면
R3	2020-01 ~ 2023-06 (42개월)	약 882일	COVID 충격·2022 긴축으로 인한 고변동성 복합 국면
R4	2023-07 ~ 2025-12 (30개월)	약 630일	AI 주도 랠리 (정상화)

부록 B. 슬롯 분석 결과 전체 표

4.3절의 평균 결과(표 4)를 보완하여, 90 슬롯 전체의 성과를 뷰 신뢰도 $\omega \in \{\omega^{\text{err}}, \omega^{\text{he}}\}$ 와 평가 지

표 $\in \{\text{Sharpe}, \text{Sortino}, \text{MDD}\}$ 의 6개 조합 표로 제공한다. 표 A.7–A.9는 $\omega = \omega^{\text{err}}$ 기준, 표 A.10–A.12는 $\omega = \omega^{\text{he}}$ 기준이다.

평가 지표는 다음 세 가지를 사용한다.

- **샤프 비율:** 평균 초과수익을 표준편차로 나눈 위험 조정 수익률. 클수록 우위.
- **Sortino 비율:** 샤프 비율의 하방 변동성 버전으로, 분모를 하방 표준편차로 대체한다(Sortino & Price, 1994). 하락 변동성만 페널티로 반영하며 클수록 우위.
- **최대낙폭 (MDD):** 누적 고점 대비 최대 손실 폭(%). 음수가 손실이므로 클수록(0에 가까울수록) 우위.

통계 검정은 샤프 비율 차이에 한하여 슬롯별로 수행하며, 그 결과는 표 A.7 및 A.10의 각 셀에 별표($p < .05$)로 표기하였다. Sortino 비율 및 MDD 등 보조 지표에 대해서는 별도의 통계 검정을 수행하지 않고 관측치 수준의 참조 지표로 첨부한다. 모든 표의 $\Delta > 0$ 셀(녹색)은 앙상블이 ANN 대비 위험 조정 수익 또는 손실 폭 측면에서 우위인 경우이다.

<표 A.7> 전체 45개 슬롯 샤프 비율 결과($\omega = \omega^{\text{err}}$ 고정). $\mathbf{p} \times \mathbf{w}_{\text{mkt}} \times \mathbf{q} = 3 \times 3 \times 5 = 45$ 슬롯 각각의 앙상블(E) · ANN(A) 샤프 비율 및 차이 $\Delta = E - A$ 를 5개 국면(All, R1 회복, R2 확장, R3 위기, R4 정상화)에 대해 보고한다. 별표(*)는 부트스트랩 검정 결과 $p < .05$.

p	w _{mkt}	q	All			R1			R2			R3			R4		
			E	A	Δ	E	A	Δ	E	A	Δ	E	A	Δ	E	A	Δ
p ^{cap}	w ^{cap}	q ^{low}	0.913	0.952	-0.038	0.821	1.041	-0.220	0.953	1.213	-0.260	0.991	0.638	+0.353	0.864	0.833	+0.030
		q ^{raw}	0.976	0.988	-0.012	0.818	1.044	-0.226	1.115	1.332	-0.217	0.999	0.643	+0.357	0.864	0.833	+0.030
		q ^{inv}	0.995	0.982	+0.014	1.061	1.244	-0.183	1.100	1.084	+0.016	0.894	0.738	+0.156	0.915	0.963	-0.048
		q ^{sp}	0.949	0.948	+0.000	0.894	1.105	-0.211	1.030	1.067	-0.037	0.943	0.720	+0.223	0.891	0.958	-0.067
		q ^{fit}	0.946	0.945	+0.000	0.738	1.059	-0.321	1.287	1.076	+0.212	0.702	0.850	-0.148	0.940	0.712	+0.228
	w ^{eq}	q ^{low}	0.895	0.947	-0.052	0.979	1.168	-0.189	0.997	1.245	-0.248	0.956	0.711	+0.244	0.505	0.518	-0.014
		q ^{raw}	0.961	0.984	-0.023	0.988	1.163	-0.176	1.175	1.382	-0.207	0.965	0.717	+0.248	0.505	0.518	-0.014
		q ^{inv}	0.905	0.940	-0.035	1.164	1.381	-0.217*	1.075	1.072	+0.003	0.823	0.756	+0.066	0.455	0.551	-0.096
		q ^{sp}	0.888	0.927	-0.038	1.042	1.226	-0.184	1.018	1.077	-0.059	0.905	0.780	+0.125	0.437	0.538	-0.101
		q ^{fit}	0.894	0.889	+0.006	0.919	1.182	-0.262	1.276	1.007	+0.269	0.673	0.862	-0.189	0.623	0.420	+0.202
	w ^{fp}	q ^{low}	0.905	0.946	-0.041	1.106	1.295	-0.189	0.977	1.229	-0.252	0.928	0.653	+0.276	0.502	0.478	+0.024
		q ^{raw}	0.966	0.983	-0.017	1.110	1.296	-0.185	1.133	1.353	-0.220	0.942	0.659	+0.283	0.502	0.478	+0.024
		q ^{inv}	0.916	0.947	-0.031	1.274	1.478	-0.204*	1.090	1.098	-0.008	0.793	0.720	+0.073	0.431	0.512	-0.081
		q ^{sp}	0.909	0.935	-0.027	1.167	1.346	-0.179	1.039	1.086	-0.046	0.881	0.742	+0.138	0.409	0.506	-0.097*
		q ^{fit}	0.918	0.904	+0.014	1.032	1.299	-0.267*	1.298	1.038	+0.260	0.638	0.829	-0.191	0.651	0.394	+0.257
p ^{eq}	w ^{cap}	q ^{low}	1.067	0.973	+0.094	1.076	1.120	-0.045	1.320	1.335	-0.016	0.956	0.583	+0.373*	0.638	0.578	+0.059
		q ^{raw}	1.060	0.976	+0.084	1.085	1.125	-0.040	1.311	1.345	-0.034	0.953	0.583	+0.370*	0.638	0.578	+0.059
		q ^{inv}	1.047	0.988	+0.059	1.240	1.270	-0.030	1.195	1.205	-0.010	0.878	0.681	+0.197*	0.816	0.720	+0.097
		q ^{sp}	1.040	0.963	+0.076	1.131	1.158	-0.028	1.205	1.245	-0.040	0.914	0.624	+0.291*	0.772	0.688	+0.084
		q ^{fit}	1.099	1.049	+0.050	0.872	1.024	-0.152	1.421	1.408	+0.013	0.888	0.705	+0.183	1.066	0.868	+0.198
	w ^{eq}	q ^{low}	1.022	0.935	+0.086	1.163	1.203	-0.040	1.339	1.350	-0.011	0.955	0.621	+0.334*	0.277	0.227	+0.050
		q ^{raw}	1.016	0.932	+0.084	1.164	1.210	-0.046	1.339	1.339	-0.000	0.953	0.622	+0.331*	0.277	0.227	+0.050
		q ^{inv}	1.008	0.947	+0.061	1.329	1.337	-0.007	1.196	1.194	+0.002	0.941	0.748	+0.193	0.397	0.349	+0.048
		q ^{sp}	1.012	0.956	+0.057	1.221	1.247	-0.026	1.239	1.285	-0.046	0.965	0.723	+0.243*	0.354	0.317	+0.038
		q ^{fit}	1.068	1.031	+0.037	1.020	1.123	-0.103	1.436	1.461	-0.025	0.956	0.802	+0.154	0.522	0.405	+0.117
	w ^{fp}	q ^{low}	1.013	0.923	+0.090	1.268	1.307	-0.039	1.317	1.312	+0.004	0.891	0.580	+0.311*	0.230	0.164	+0.066
		q ^{raw}	1.008	0.922	+0.085	1.272	1.313	-0.041	1.314	1.307	+0.007	0.888	0.581	+0.307*	0.230	0.164	+0.066
		q ^{inv}	1.012	0.948	+0.064	1.462	1.428	+0.034	1.218	1.199	+0.019	0.884	0.723	+0.160	0.350	0.296	+0.053
		q ^{sp}	1.014	0.957	+0.056	1.339	1.362	-0.023	1.238	1.274	-0.036	0.908	0.688	+0.220*	0.326	0.274	+0.052
		q ^{fit}	1.081	1.043	+0.038	1.116	1.225	-0.109	1.453	1.454	-0.000	0.908	0.776	+0.132	0.484	0.374	+0.110
p ^{fp}	w ^{cap}	q ^{low}	1.042	0.940	+0.101	0.977	0.956	+0.021	1.275	1.285	-0.010	0.953	0.620	+0.333	0.709	0.647	+0.061
		q ^{raw}	1.036	0.956	+0.080	0.986	0.955	+0.031	1.270	1.330	-0.060	0.951	0.621	+0.329	0.709	0.647	+0.061
		q ^{inv}	1.020	0.922	+0.098	1.137	1.001	+0.136	1.151	1.129	+0.023	0.852	0.679	+0.172	0.926	0.808	+0.117
		q ^{sp}	1.009	0.906	+0.103	1.055	0.977	+0.078	1.150	1.151	-0.001	0.884	0.631	+0.254	0.871	0.769	+0.102

롯 각각의 앙상블(E) · ANN(A) 최대낙폭 (MDD) 및 차이 $\Delta = E - A$ 를 5개 국면(A11, R1 회복, R2 확장, R3 위기, R4 정상화)에 대해 보고한다. MDD는 음수가 손실이므로 $\Delta > 0$ 이 앙상블이 덜 빠진 경우이다.

p	w _{mkt}	q	A11			R1			R2			R3			R4		
			E	A	Δ	E	A	Δ	E	A	Δ	E	A	Δ	E	A	Δ
p	w ^{mcap}	q ^{lmm}	-11.65%	-13.81%	+2.16%	-10.74%	-10.37%	-0.38%	-11.65%	-11.33%	-0.32%	-10.05%	-13.81%	+3.77%	-4.91%	-5.91%	+1.00%
		q ^{raw}	-13.69%	-13.81%	+0.12%	-10.79%	-10.45%	-0.34%	-13.69%	-13.45%	-0.24%	-10.05%	-13.81%	+3.77%	-4.91%	-5.91%	+1.00%
		q ^{inv}	-14.76%	-15.37%	+0.61%	-7.43%	-7.13%	-0.30%	-11.76%	-12.87%	+1.11%	-13.39%	-15.37%	+1.98%	-5.31%	-7.17%	+1.86%
		q ^{isp}	-12.73%	-14.35%	+1.63%	-9.54%	-9.26%	-0.28%	-9.46%	-11.42%	+1.96%	-12.48%	-14.35%	+1.87%	-5.19%	-7.19%	+2.01%
		q ^{it3}	-19.84%	-18.91%	-0.92%	-11.90%	-10.47%	-1.43%	-16.60%	-12.84%	-3.76%	-19.84%	-15.17%	-4.66%	-18.74%	-18.91%	+0.17%
	w ^{sq}	q ^{lmm}	-12.18%	-13.01%	+0.83%	-12.18%	-11.51%	-0.66%	-11.50%	-12.09%	+0.59%	-9.79%	-13.01%	+3.22%	-6.83%	-7.18%	+0.35%
		q ^{raw}	-14.19%	-14.05%	-0.14%	-12.18%	-11.51%	-0.66%	-14.19%	-14.05%	-0.14%	-9.79%	-13.01%	+3.22%	-6.83%	-7.18%	+0.35%
		q ^{inv}	-18.88%	-17.89%	-0.98%	-7.57%	-6.31%	-1.26%	-12.18%	-12.44%	+0.26%	-13.28%	-14.77%	+1.49%	-8.64%	-9.33%	+0.69%
		q ^{isp}	-15.65%	-15.12%	-0.52%	-10.31%	-10.00%	-0.31%	-9.79%	-11.03%	+1.24%	-11.97%	-14.35%	+2.38%	-8.29%	-9.19%	+0.89%
		q ^{it3}	-24.34%	-19.65%	-4.69%	-12.73%	-10.07%	-2.66%	-17.61%	-12.58%	-5.04%	-19.41%	-14.22%	-5.20%	-20.34%	-19.65%	-0.69%
	w ^{ip}	q ^{lmm}	-12.56%	-12.65%	+0.09%	-10.44%	-9.77%	-0.67%	-11.70%	-12.65%	+0.95%	-10.15%	-12.24%	+2.09%	-6.81%	-6.84%	+0.03%
		q ^{raw}	-14.37%	-13.81%	-0.56%	-10.44%	-9.77%	-0.67%	-14.37%	-13.81%	-0.56%	-10.15%	-12.24%	+2.09%	-6.81%	-6.84%	+0.03%
		q ^{inv}	-17.57%	-16.73%	-0.84%	-6.56%	-5.56%	-1.00%	-11.78%	-11.81%	+0.04%	-12.56%	-14.13%	+1.57%	-7.58%	-8.31%	+0.73%
		q ^{isp}	-14.51%	-14.19%	-0.33%	-8.69%	-8.24%	-0.45%	-9.46%	-10.57%	+1.11%	-11.40%	-13.84%	+2.44%	-7.40%	-8.24%	+0.84%
		q ^{it3}	-22.39%	-19.01%	-3.38%	-10.85%	-8.38%	-2.47%	-16.89%	-11.93%	-4.97%	-17.57%	-13.43%	-4.14%	-19.62%	-19.01%	-0.60%
	w ^{mcap}	q ^{lmm}	-12.82%	-14.16%	+1.34%	-9.97%	-10.51%	+0.53%	-12.82%	-13.37%	+0.55%	-10.99%	-14.16%	+3.17%	-5.35%	-5.12%	-0.23%
		q ^{raw}	-15.16%	-15.46%	+0.30%	-9.97%	-10.51%	+0.53%	-15.16%	-15.46%	+0.30%	-10.99%	-14.16%	+3.17%	-5.35%	-5.12%	-0.23%
		q ^{inv}	-14.46%	-16.41%	+1.95%	-5.95%	-6.25%	+0.30%	-10.81%	-11.45%	+0.63%	-14.46%	-16.41%	+1.95%	-5.23%	-4.79%	-0.44%
		q ^{isp}	-12.64%	-15.47%	+2.83%	-8.56%	-8.84%	+0.28%	-8.70%	-9.39%	+0.69%	-12.64%	-15.47%	+2.83%	-5.37%	-4.94%	-0.43%
		q ^{it3}	-16.01%	-15.84%	-0.16%	-13.82%	-11.96%	-1.85%	-10.22%	-8.53%	-1.69%	-16.01%	-15.84%	-0.16%	-7.44%	-7.60%	+0.16%
	p ^{sq}	q ^{lmm}	-13.31%	-13.52%	+0.20%	-10.36%	-10.46%	+0.10%	-13.31%	-13.52%	+0.20%	-10.46%	-12.41%	+1.95%	-7.06%	-6.78%	-0.28%
		q ^{raw}	-15.11%	-15.54%	+0.44%	-10.36%	-10.46%	+0.10%	-15.11%	-15.54%	+0.44%	-10.46%	-12.41%	+1.95%	-7.06%	-6.78%	-0.28%
		q ^{inv}	-16.87%	-16.79%	-0.08%	-5.80%	-5.79%	-0.01%	-10.57%	-11.07%	+0.51%	-13.23%	-14.15%	+0.92%	-7.37%	-6.81%	-0.55%
		q ^{isp}	-14.20%	-14.57%	+0.36%	-8.24%	-8.81%	+0.57%	-8.59%	-9.19%	+0.60%	-12.71%	-13.75%	+1.04%	-7.59%	-7.07%	-0.52%
		q ^{it3}	-14.26%	-13.59%	-0.68%	-12.43%	-11.48%	-0.95%	-9.84%	-8.23%	-1.61%	-13.84%	-13.59%	-0.25%	-9.03%	-9.18%	+0.15%
	w ^{ip}	q ^{lmm}	-13.34%	-13.51%	+0.17%	-8.96%	-8.82%	-0.14%	-13.34%	-13.51%	+0.17%	-9.81%	-11.88%	+2.07%	-6.76%	-6.75%	-0.02%
		q ^{raw}	-15.07%	-15.53%	+0.46%	-8.96%	-8.82%	-0.14%	-15.07%	-15.53%	+0.46%	-9.81%	-11.88%	+2.07%	-6.76%	-6.75%	-0.02%
		q ^{inv}	-16.28%	-16.10%	-0.18%	-5.46%	-5.62%	+0.15%	-10.16%	-10.61%	+0.45%	-12.86%	-13.45%	+0.60%	-6.90%	-6.68%	-0.23%
		q ^{isp}	-13.47%	-13.90%	+0.43%	-7.02%	-7.11%	+0.09%	-8.30%	-8.87%	+0.57%	-12.03%	-13.04%	+1.02%	-7.06%	-6.67%	-0.40%
		q ^{it3}	-14.32%	-12.87%	-1.45%	-11.06%	-9.91%	-1.15%	-9.48%	-8.15%	-1.33%	-13.39%	-12.87%	-0.51%	-8.51%	-8.61%	+0.10%
	w ^{mcap}	q ^{lmm}	-11.87%	-14.19%	+2.32%	-11.87%	-14.19%	+2.32%	-11.64%	-11.84%	+0.20%	-11.06%	-13.94%	+2.87%	-5.25%	-4.96%	-0.29%
		q ^{raw}	-13.78%	-14.68%	+0.90%	-11.87%	-14.19%	+2.32%	-13.78%	-14.68%	+0.90%	-11.06%	-13.94%	+2.87%	-5.25%	-4.96%	-0.29%
		q ^{inv}	-14.61%	-16.25%	+1.64%	-6.36%	-13.99%	+7.63%	-11.85%	-12.03%	+0.18%	-14.61%	-16.25%	+1.64%	-5.12%	-4.84%	-0.28%
		q ^{isp}	-12.88%	-15.39%	+2.51%	-9.51%	-14.09%	+4.58%	-9.18%	-9.63%	+0.45%	-12.88%	-15.39%	+2.51%	-5.19%	-4.93%	-0.26%
		q ^{it3}	-16.24%	-15.66%	-0.58%	-16.24%	-13.81%	-2.43%	-10.49%	-8.54%	-1.95%	-15.93%	-15.66%	-0.27%	-7.60%	-7.51%	-0.09%
	p ^{ip}	q ^{lmm}	-12.42%	-13.57%	+1.15%	-11.30%	-13.57%	+2.27%	-12.39%	-12.11%	-0.28%	-10.43%	-12.10%	+1.66%	-6.96%	-6.82%	-0.14%
		q ^{raw}	-14.16%	-14.63%	+0.47%	-11.30%	-13.57%	+2.26%	-14.16%	-14.63%	+0.47%	-10.43%	-12.10%	+1.66%	-6.96%	-6.82%	-0.14%
		q ^{inv}	-16.99%	-17.01%	+0.03%	-6.23%	-13.39%	+7.16%	-11.78%	-11.84%	+0.05%	-13.17%	-14.01%	+0.84%	-7.32%	-6.87%	-0.45%
		q ^{isp}	-14.68%	-14.93%	+0.25%	-9.30%	-13.48%	+4.19%	-9.11%	-9.33%	+0.22%	-12.59%	-13.56%	+0.97%	-7.54%	-7.13%	-0.41%
		q ^{it3}	-14.51%	-13.49%	-1.02%	-14.51%	-13.07%	-1.44%	-9.97%	-8.19%	-1.78%	-13.66%	-13.49%	-0.17%	-9.38%	-9.16%	-0.22%
	w ^{ip}	q ^{lmm}	-13.11%	-12.18%	-0.94%	-9.58%	-12.13%	+2.55%	-12.57%	-12.18%	-0.39%	-9.90%	-11.90%	+1.99%	-6.77%	-6.75%	-0.03%
		q ^{raw}	-14.24%	-14.56%	+0.32%	-9.58%	-12.12%	+2.54%	-14.24%	-14.56%	+0.32%	-9.90%	-11.90%	+1.99%	-6.77%	-6.75%	-0.03%
		q ^{inv}	-16.41%	-16.26%	-0.14%	-5.57%	-11.94%	+6.36%	-11.10%	-11.21%	+0.11%	-12.81%	-13.36%	+0.55%	-6.83%	-6.73%	-0.10%
		q ^{isp}	-13.91%	-14.03%	+0.13%	-7.82%	-12.03%	+4.21%	-8.82%	-9.03%	+0.21%	-12.05%	-12.98%	+0.94%	-7.00%	-6.72%	-0.28%
		q ^{it3}	-13.90%	-12.70%	-1.21%	-12.72%	-11.34%	-1.38%	-9.55%	-7.99%	-1.56%	-13.19%	-12.70%	-0.50%	-8.83%	-8.60%	-0.23%

부록 C. R1 회복 국면 결과 분석

본 부록은 5절 셋째 한계에서 인용한 R1 국면 손실의 시점 집중성(약 76%, 40%) 및 4.3절의 표 5에서 관찰된 **p** 의존적 비대칭의 정량적 근거를 제공한다.

C.1 R1 국면 **p** 벡터 방식별 앙상블-ANN 격차

본문 4.3절 표 5에서 샤프 비율 기준 **p** 방식별 앙상블 순위 슬롯 수를 보고하였다. 본 부록은 보조 지표로 누적 수익률 차이를 함께 제시한다(각 **p** 별 15 슬롯 평균, R1 30 개월 누적).

<표 A.13> R1 회복 국면 $\mathbf{p}$ 방식별 앙상블 vs ANN 격차 — 평균 Δ Sharpe, 앙상블 우위 슬롯 수, 누적 Δ Return 세 지표. 각 $\mathbf{p}$ 값에 대해 $q \times \mathbf{w}_{mkt} = 15$ 슬롯 평균.

$\mathbf{p}$	평균 Δ 샤프 비율($E - A$)	앙상블 우위 슬롯	R1 누적 Δ Return
$\mathbf{p}^{\text{mcap}}$	-0.214	0 / 15	-7.75%
$\mathbf{p}^{\text{eq}}$	-0.046	1 / 15	-1.74%
$\mathbf{p}^{\text{rp}}$	+0.081	14 / 15	+0.19%

Δ Return = (앙상블 누적 수익) - (ANN 누적 수익), 각 $\mathbf{p}$ 별 15 슬롯 평균.

R1 앙상블 열위는 $\mathbf{p}^{\text{mcap}}$ 조건에서 가장 두드러지며 (-7.75%), $\mathbf{p}^{\text{eq}}$ 에서 격차가 큰 폭 완화되고 (-1.74%), $\mathbf{p}^{\text{rp}}$ 에서는 사실상 사라진다 (+0.19%).

C.2 $\mathbf{p}^{\text{mcap}}$ 누적 손실의 시점 집중성

$\mathbf{p}^{\text{mcap}}$ 누적 손실 -7.75%의 월별 분포를 보면, 약 76%가 2011 3·4·8월의 세 시점에 집중된다.

<표 A.14> $\mathbf{p}^{\text{mcap}}$ 누적 손실의 시점 집중성 — R1 30개월 중 2011년 3·4·8월 세 시점이 누적 손실의 약 76%를 차지한다.

시점	시장 이벤트	Δ Return ($\mathbf{p}^{\text{mcap}}$)	기여도
2011-03	Tohoku 지진 + 일본 시장 충격	-1.19%p	15.4%
2011-04	포르투갈 구제금융 신청 + 유럽 재정위기 재발	-1.65%p	21.3%
2011-08	유로존 위기 + 미국 신용등급 강등	-3.08%p	39.7%
위 3 개 합계	-	-5.92%p	76.4%
나머지 27 개월	-	-1.83%p	23.6%
R1 누적 합계	-	-7.75%p	100.0%

2011-08 단일 월이 R1 누적 손실의 약 40%를 견인하며, 30개월 R1 국면 손실의 대부분이 2011년 3·4·8월 세 시점에 집중된다. 이러한 표본 크기와 분포의 집중성을 고려할 때, R1 국면 결과는 회복 국면 일반에 대한 결론으로 확장하기 어렵다.

부록 D. R4 정상화 국면의 q^{ff3} 부호 반전과 $\mathbf{p}$ 벡터의 완화 효과

본 부록은 5절에서 언급한 Pyo and Lee(2018)가 사용한 Fama-French 회귀 기반 q^{ff3} 이 시장 상황에 따라 부호가 반전되면서 저변동 전략의 본질이 약화될 수 있다"는 관찰의 정량적 근거를 제공한다. 본 부록의 모든 분석은 사후적 관찰에 머무르며, 인과적 메커니즘의 규명은 본 연구의 범위를 벗어난다.

D.1 앵커 슬롯의 국면별 비중 추이

Pyo and Lee (2018)가 제안한 앵커 슬롯 mcap_mcap_ff3_err 의 저변동·고변동 종목 비중을 4 개 국면에 걸쳐 집계한 결과는 다음과 같다.

<표 A.15> 앵커 슬롯(mcap_mcap_ff3_err)의 국면별 저변동·고변동 비중 추이. 저변동 / 고변동은 변동성 예측값 하위 30% / 상위 30%로 정의하며, 각 셀은 월별 평균.

국면	양상블 (E)			ANN (A)		
	저변동	고변동	스프레드	저변동	고변동	스프레드
R1 회복	0.556	0.087	+0.469	0.598	0.082	+0.516
R2 확장	0.431	0.205	+0.226	0.453	0.181	+0.272
R3 위기	0.403	0.212	+0.190	0.420	0.198	+0.222
R4 정상화	0.250	0.395	-0.145	0.263	0.366	-0.103

R1 국면에서 R3 국면까지는 저변동 비중이 고변동 비중보다 큰 저변동 전략이 유지되었으나, R4 국면에서 양상블·ANN 모형 모두 변동성 스프레드가 음수로 전환되어 저변동 전략의 본질이 사실상 반전된 상태로 운용되었다.

D.2 q^{ff3} 의 국면별 부호 분포

앵커 슬롯에서 q^{ff3} 의 월별 평균값과 음수 비율을 국면별로 집계한 결과는 다음과 같다.

<표 A.16> 앵커 슬롯 (mcap_mcap_ff3_err)의 q^{ff3} 국면별 부호 분포 — R4에서 평균값과 음수 빈도가 모두 극단적으로 증가.

국면	양상블 (E)		ANN (A)	
	mean(q)	% q < 0	mean(q)	% q < 0
R1 회복	+0.0001	43.3%	+0.0022	3.3%
R2 확장	-0.0010	61.1%	-0.0001	44.4%
R3 위기	-0.0009	69.0%	-0.0000	40.5%
R4 정상화	-0.0100	80.0%	-0.0099	90.0%

R4 국면에서 q^{ff3} 의 평균값은 다른 국면 대비 높은 음수 값을 보이며, 음수 발생 빈도도 80% 수준에 도달한다. BL 사후 추정에서 p 와 q 항의 부호는 q 의 부호에 의해 결정되므로, R4 국면에서는 저변동(p 의 양의 가중)·고변동(p 의 음의 가중)에 대한 류의 방향이 반전되어 고변동 롱·저변동 숏으로 작동한다.



<그림 A.1> q^{ff3} (파란 원, FF3 회귀 기반)과 q^{lam} (초록 사각, λ_q 기반)의 월별 시계열 — 앵커 슬롯 mcap_mcap_ff3_err 기준. 빨간 점선은 부호 반전 임계선(0), 음영은 4개 국면. q^{lam} 은 전 기간 양수를 유지하나, q^{ff3} 은 빈번한 부호 반전 후 R4 국면에서 강한 음수로 수렴한다.

그림 A.1 은 Pyo and Lee(2018)가 제안한 앵커 슬롯의 q^{ff3} 과 동일 앵커에서 q 만 q^{lam} 으로 교체한 경우의 값을 시각화한 것이다. FF3 기반의 q^{ff3} 은 R1R3 국면에서도 부호 반전을 자주 보이며 R4 에 들어서면 0 아래에 머물러 뷰 방향이 반전된 상태가 유지되는 반면, 양수 clip 범위를 갖는 λ_q 기반의 q^{lam} (3.3.1절 정의) 은 전 기간 양수를 유지하여 저변동 뷰의 일관성을 보존한다.

D.3 $\mathbf{p}$ 벡터 변경의 완화 효과

R4 정상화 국면에서 $\mathbf{w}_{mkt} = \mathbf{w}^{mcap}, \omega = \omega^{err}$ 을 고정한 채 $\mathbf{p}$ 와 q 를 변경한 모든 조합의 스프레드는 다음과 같다(양상불 기준).

<표 A.17> R4 정상화 국면에서 $\mathbf{w}_{mkt} = \mathbf{w}^{mcap}, \omega = \omega^{err}$ 고정 후 $\mathbf{p}$ 와 q 를 변경한 모든 조합의 스프레드(저변동 – 고변동, 양상불 기준). ($\mathbf{p}^{mcap}, q^{ff3}$) 한 조합에서만 음수로 반전된다.

스프레드 (저-고)	q^{lam}	q^{raw}	q^{inv}	q^{vsp}	q^{ff3}
$\mathbf{p}^{mcap}$	+0.290	+0.290	+0.229	+0.236	-0.145
$\mathbf{p}^{eq}$	+0.335	+0.335	+0.267	+0.278	+0.146
$\mathbf{p}^{rp}$	+0.332	+0.332	+0.265	+0.277	+0.153

R4 국면에서 스프레드가 음수로 전환되는 조합은 ($\mathbf{p}^{mcap}, q^{ff3}$) 단 1개에 불과하며, 동일한 q^{ff3} 을 사용하더라도 $\mathbf{p}$ 를 $\mathbf{p}^{eq}$ 또는 $\mathbf{p}^{rp}$ 로 변경하면 스프레드가 양수(+0.146, +0.153)로 회복된다. ANN 기준에서도 같은 패턴이 관찰되며($\mathbf{p}^{mcap} \cdot q^{ff3}$: -0.103, $\mathbf{p}^{eq} \cdot q^{ff3}$: +0.165, $\mathbf{p}^{rp} \cdot q^{ff3}$: +0.179), 양수 제약이 있는 q 와 결합된 $\mathbf{p}$ 는 모든 조합에서 스프레드 0.200.34 수준의 저변동 우위 뷰를 유지한다.

즉, R4 국면에서 저변동 전략 본질의 반전은 $\mathbf{p}^{mcap}$ 가중과 q^{ff3} 의 결합 조건에서만 관찰되며, 두 요소 중 어느 한쪽이라도 변경되면 저변동 본질이 부분적 또는 완전 회복된다.

부록 E. 벤치마크 대비 보조 지표

4.4절(벤치마크 성능 비교)에서 보고한 샤프 비율 결과(표 6)에 대응하여, 동일한 슬롯과 5개 기간(All, R1 회복, R2 확장, R3 위기, R4 정상화)에 대한 보조 지표 3종을 첨부한다. 표 A.18는 Sortino 비율, 표 A.19 는 최대낙폭 (MDD), 표 A.20은 연환산 수익률을 보고하며, 각 표에서 4개 Ensemble 슬롯 중 컬럼별 최우수 값을 굵게 표시한다. Sortino 비율과 연환산 수익률은 클수록, MDD는 0에 가까울수록 우위이며, 부록 B와 마찬가지로 관측치 수준의 참조 지표로만 첨부한다.

<표 A.18> 벤치마크 성능 비교 — Sortino 비율 $\times$ 5기간. 4개 Ensemble 슬롯 중 컬럼별 최대값 굵게 표시.

Strategy	All	R1	R2	R3	R4
SPY (market)	1.38	1.41	1.66	1.06	2.36
1/N (equal-weight)	1.21	1.32	1.47	1.08	0.88
Risk Parity (1/ σ)	1.25	1.72	1.50	1.05	0.81
ANN-anchor (Pyo & Lee, 2018)	1.34	1.56	1.36	1.60	0.88
Ensemble-anchor (σ 모형 교체)	1.32	1.19	1.48	1.17	1.51
Ensemble-defensive (p^{eq}, q^{lam})	1.66	1.78	1.82	1.80	0.98
Ensemble-defensive (p^{rp}, q^{lam})	1.64	1.67	1.75	1.79	1.10
Ensemble-adaptive (p^{eq}, q^{f3})	1.62	1.47	1.70	1.77	1.72
Ensemble-adaptive (p^{rp}, q^{f3})	1.59	1.44	1.64	1.75	1.78

<표 A.19> 벤치마크 성능 비교 — 최대낙폭 (MDD) $\times$ 5 기간(0에 가까울수록 우위). 4개 Ensemble 슬롯 중 컬럼별 최우수(절대값 최소) 굵게 표시.

Strategy	All	R1	R2	R3	R4
SPY (market)	-23.9%	-16.2%	-13.5%	-23.9%	-7.6%
1/N (equal-weight)	-24.3%	-21.4%	-17.3%	-16.8%	-12.0%
Risk Parity (1/ σ)	-22.0%	-18.2%	-15.8%	-16.1%	-10.4%
ANN-anchor (Pyo & Lee, 2018)	-18.4%	-12.5%	-16.1%	-16.1%	-18.4%
Ensemble-anchor (σ 모형 교체)	-20.5%	-17.1%	-17.6%	-16.5%	-14.0%
Ensemble-defensive (p^{eq}, q^{lam})	-14.7%	-12.8%	-8.2%	-14.7%	-8.9%
Ensemble-defensive (p^{rp}, q^{lam})	-14.0%	-14.0%	-8.5%	-13.4%	-8.7%
Ensemble-adaptive (p^{eq}, q^{f3})	-15.7%	-15.7%	-11.4%	-15.1%	-7.9%
Ensemble-adaptive (p^{rp}, q^{f3})	-19.2%	-19.2%	-12.6%	-15.0%	-7.5%

<표 A.20> 벤치마크 성능 비교 — 연환산 수익률 $\times$ 5 기간. 4개 Ensemble 슬롯 중 컬럼별 최대값 굵게 표시.

Strategy	All	R1	R2	R3	R4
SPY (market)	+14.4%	+12.7%	+14.2%	+12.4%	+19.7%
1/N (equal-weight)	+14.8%	+14.3%	+16.1%	+15.5%	+10.5%
Risk Parity (1/ σ)	+14.2%	+14.9%	+15.6%	+13.9%	+9.8%
ANN-anchor (Pyo & Lee, 2018)	+14.3%	+16.6%	+12.9%	+15.0%	+15.2%
Ensemble-anchor (σ 모형 교체)	+15.1%	+11.4%	+15.9%	+14.2%	+17.9%
Ensemble-defensive (p^{eq}, q^{lam})	+15.1%	+17.2%	+15.1%	+16.7%	+11.1%
Ensemble-defensive (p^{rp}, q^{lam})	+14.7%	+15.2%	+14.7%	+16.5%	+11.9%
Ensemble-adaptive (p^{eq}, q^{f3})	+15.9%	+14.0%	+16.4%	+15.7%	+16.4%
Ensemble-adaptive (p^{rp}, q^{f3})	+15.3%	+13.1%	+15.6%	+15.3%	+16.8%

저자소개



서운범

경북대학교에서 통계학 전공으로 학사 및 석사 학위를 취득하였으며, 스파르타 데이터 분석 부트캠프 11기를 수료하였다. 재현 데이터(Synthetic Data) 관련 연구를 SCI 저널에 게재한 바 있으며, 주요 관심분야는 재현데이터, 머신러닝, 딥러닝이다.



김하연

숙명여자대학교에서 통계학 학사 학위를 취득하였으며, 스파르타 데이터 분석 부트캠프 11기를 수료하였다. 주요 관심 분야는 데이터 분석 및 통계 모델링이다.



김재천

가천대학교에서 경제학 학사 학위를 취득하였으며, 스파르타 데이터 분석 부트캠프 11기를 수료하였다. 관심 분야는 금융 데이터 분석, 머신러닝, 인공지능이다.



김윤서

숙명여자대학교에서 소프트웨어융합전공으로 학사 학위를 취득하였으며, 스파르타 데이터 분석 부트캠프 11기를 수료하였다. 주요 관심 분야는 데이터사이언스, 머신러닝, 금융데이터 분석이다.



서정욱

한양대학교 인공지능융합학과 박사과정에 재학 중이며, 주요 연구 분야는 이상탐지, 시계열 데이터 분석, 예지보전, 컴퓨터 비전 및 멀티모달 인공지능이다. 제조 설비 데이터를 활용한 예지보전 연구와 Vision-Language Model 기반 감정 인식 연구를 수행하고 있으며, 딥러닝 및 머신러닝 기반 산업 인공지능 응용에 관심을 가지고 있다. 또한 SCI급 국제학술지 논문 게재 및 다양한 산학협력 연구 프로젝트에 참여하고 있다.